

PRACA DYPLOMOWA INŻYNIERSKA

Automatyzacja i optymalizacja procesów produkcji w rolnictwie z wykorzystaniem sztucznej inteligencji i baz danych

*Automation and optimization of production processes in
agriculture using artificial intelligence and databases*

Piotr Szczerbiak

Nr albumu: 137204

Kierunek: Matematyka Stosowana i
Technologie Informatyczne

Forma studiów: stacjonarne

Poziom studiów: I

Promotor pracy: dr inż. Olga
Siedlecka-Lamch

Praca przyjęta dnia:

Podpis promotora:

Częstochowa, 06.01.2026r.

Spis treści

1	Wprowadzenie	5
2	Cel i zakres pracy:	9
3	Automatyzacja i optymalizacja procesów produkcji w rolnictwie:	11
3.1	Charakterystyka współczesnego rolnictwa precyzyjnego:	11
3.2	Wyzwania w procesach produkcyjnych gospodarstw rolnych....	13
3.3	Trendy i kierunki rozwoju digitalizacji rolnictwa	14
3.4	Wykorzystanie danych satelitarnych i dronowych	16
3.5	Wskaźnik NDVI – teoria i zastosowania.....	17
3.6	Algorytmy uczenia maszynowego w rolnictwie	19
3.7	Rola relacyjnych baz danych w systemach rolniczych.....	20
4	Projekt systemu do automatyzacji i analizy danych rolniczych:	22
4.1	Analiza wymagań i założenia projektowe systemu:	22
4.2	Specyfikacja funkcjonalna.....	23
4.3	Architektura systemu	26
4.4	Warstwa frontend (HTML, CSS, JavaScript).....	27
4.5	Warstwa backend (ASP.NET / C#)	28
4.6	Integracja z Oracle przez ADO.NET	29
4.7	Zewnętrzna baza danych Oracle i środowisko SQL Developer .	30
4.8	Projekt bazy danych:.....	31
4.9	Warstwa analityczna Python + Python.NET	35
4.10	Zewnętrzne usługi mapowe (OpenStreetMap).....	36
4.11	Integracja z usługami publicznymi Geoportal.....	37
4.12	Dane pogodowe OpenMeteo	38
4.13	Sterownik GDAL	39
5	Implementacja aplikacji	40
5.1	Konfiguracja środowiska programistycznego	40

5.2	Inicjalizacja i konfiguracja aplikacji.....	42
5.3	Logowanie i rejestracja	42
5.4	Moduł GIS – Zarządzanie Gospodarstwem i Polami	43
5.5	Procedura Importu Danych Satelitarnych	47
5.6	Wizualizacja NDVI	51
5.7	Moduł Analizy Zaawansowanej – Klastrowanie DBSCAN	53
5.8	Dodatkowe funkcjonalności i personalizacja systemu.....	56
6	Wnioski i kierunki dalszego rozwoju.....	57
7	Bibliografia:	60
8	Spis rysunków:.....	63
9	Streszczenie	64
10	Abstract	66

1 Wprowadzenie

Szybki rozwój technologii, obserwowany szczególnie w ostatnich dekadach, w znaczny sposób zmienił funkcjonowanie współczesnego społeczeństwa. Urządzenia obliczeniowe, niegdyś będące narzędziami zarezerwowanymi dla wąskiej grupy specjalistów, obecnie stały się powszechnym elementem życia codziennego, nierzadko niezbędnym do normalnego funkcjonowania. Smartfony, komputery czy tablety pełnią rolę zarówno narzędzi pracy, jak i rekreacji, dając każdemu użytkownikowi na wyciągnięcie ręki dostęp do olbrzymiej ilości treści. Równolegle gwałtownemu rozwojowi uległa sztucznej inteligencji, która w ostatnich latach przeszła z fazy badań i eksperymentów do narzędzia powszechnego, powoli stając się kluczowym elementem nowoczesnych technologii. Algorytmy uczenia maszynowego przejmują zadania związane z analizą danych, czy obrazu, przewyższając człowieka już nie tylko pod względem szybkości, ale i precyzji, co potwierdzają liczne badania [1].

Rolnictwo, choć często postrzegane jako dziedzina konserwatywna, wolniej adaptująca innowacje, w rzeczywistości garściami czerpało z odkryć i wynalazków, samemu będąc często impulsem do ich tworzenia. Można wymienić choćby badania, które wskazują, że jego upowszechnienie na skraju prehistorii doprowadziło do wyraźnego wzrostu populacji, co, razem z potrzebą sprawowania pieczy nad uprawami sprzyjało powstawaniu osiadłych wspólnot oraz przekształcaniu krajobrazu na potrzeby produkcji żywności, co dziś jest nazywane rewolucją neolityczną [2].

Przez kolejne stulecia rolnictwo stanowiło kluczową siłę napędową postępu. Przykładem z historii może być obróbka żelaza, której dynamiczne upowszechnienie wynikało między innymi z zapotrzebowania na wytrzymalsze narzędzia, takie jak nowe typy pługa czy brony. Współcześnie sektor ten ponownie staje się jednym z najważniejszych obszarów implementacji innowacji – tym razem cyfrowych. Według analiz McKinsey & Company, w obliczu konieczności zwiększenia globalnej produkcji żywności o 70% do 2050 roku (zgodnie z prognozami FAO), kluczową rolę odegrają właśnie technologie teleinformatyczne. Raport wskazuje, że sama poprawa łączności w rolnictwie posiada potencjał wygenerowania

dodatkowych 500 miliardów dolarów wartości do globalnego PKB do 2030 roku [3].

Nowoczesne gospodarstwa rolne wykorzystują dziś złożone systemy czujników, dane telemetryczne z maszyn, automatyczne sterowanie pojazdami a nawet obrazowanie satelitarne, także z wykorzystaniem dronów. Dane pozyskiwane tą drogą umożliwiają szczegółową analizę kondycji upraw, wilgotności gleby czy efektywności nawożenia. Kluczową rolę odgrywają tu wskaźniki roślinności, takie jak choćby NDVI (Normalized Difference Vegetation Index), szeroko stosowany do oceny zdrowia i wigoru roślin [4].

W ostatnich latach w obszarach rolnictwa coraz większe znaczenie zyskują również algorytmy sztucznej inteligencji, umożliwiające automatyzację analizy obrazów, wykrywanie anomalii oraz tworzenie modeli predykcyjnych i klasyfikujących. Nowoczesne systemy rolnictwa precyzyjnego wykorzystują techniki uczenia maszynowego do monitorowania upraw, prognozowania plonów oraz podejmowania decyzji produkcyjnych w czasie rzeczywistym, nierzadko osiągając dokładność znacznie przewyższającą tradycyjne, manualne metody. Rozwiązania te rozwijane są nie tylko z pobudek badawczych, lecz przede wszystkim z realnych potrzeb ekonomicznych i środowiskowych. Pomagają one bowiem zwiększyć wydajność produkcji, jednocześnie ograniczając zużycie zasobów i negatywny wpływ na przyrodę.

W dyskusji tej łatwo pominąć fakt, że rozwój jakichkolwiek algorytmów analizy jest nierozzerwalnie związany z dostępnością do danych, ich składowaniem oraz możliwością przetwarzania. Stanowią one fundament współczesnych modeli sztucznej inteligencji, wpływając na sposób, w jaki podejmowane są działania w niemal wszystkich sektorach gospodarki, także rolnictwie. Wymaga to wykorzystania zaawansowanych baz danych, przygotowanych do przyjmowania i obróbki olbrzymiej ilości danych numerycznych, tekstowych, czy zdjęć wielopasmowych.

W kontekście powyższych zjawisk rozwój systemów umożliwiających gromadzenie, przetwarzanie i analizę danych rolniczych, a także wspierających podejmowanie decyzji, stanowi istotny kierunek badań. Szczególne znaczenie mają rozwiązania integrujące technologie webowe, zaawansowane bazy danych oraz algorytmy sztucznej inteligencji,

umożliwiające tworzenie kompleksowych narzędzi wspomagających pracę rolnika, dostępnych dzięki technologii chmurowej z niemal każdego miejsca z dostępem do Internetu. Z tego względu podjęcie tematyki automatyzacji i optymalizacji procesów produkcyjnych w rolnictwie przy wykorzystaniu sztucznej inteligencji oraz baz danych jest w pełni uzasadnione, wpisując się dobrze w aktualne kierunki rozwoju sektora rolnego i technologicznego.

2 Cel i zakres pracy:

Głównym problemem poruszonym w pracy jest optymalizacja procesów decyzyjnych we współczesnym rolnictwie precyzyjnym. Dynamiczny rozwój technologii teledetekcyjnych sprawia, że gospodarstwa rolne generują i mają dostęp do olbrzymich zbiorów danych, w tym obrazów satelitarnych. Istotnym problemem badawczym i inżynierskim jest brak rodzimych, tanich i łatwo dostępnych narzędzi, które pozwalałyby na automatyczną interpretację tych danych w celu wykrywania zagrożeń upraw. Ręczna analiza zdjęć wielospektralnych jest czasochłonna i wymaga specjalistycznej wiedzy, co stwarza zapotrzebowanie na systemy automatyzujące ten proces przy użyciu nowoczesnych technologii informatycznych.

Celem teoretycznym pracy była analiza istniejących metod przetwarzania i składowania danych przestrzennych oraz ocena przydatności algorytmów sztucznej inteligencji w rolnictwie. W ramach tej części przeanalizowano potencjał analityczny danych teledetekcyjnych (satelitarnych i dronowych), skupiając się na możliwościach uzyskania informacji o kondycji roślin (m.in. poprzez wskaźnik NDVI). Ponadto zbadano możliwości wykorzystania uczenia maszynowego do wykrywania anomalii na polach uprawnych. Istotnym elementem badań teoretycznych było również porównanie technologii bazodanowych pod kątem efektywności przechowywania danych rastrowych, co doprowadziło do wyboru zaawansowanego systemu relacyjno-obiektowego Oracle Database jako fundamentu warstwy danych.

Realizacją celu praktycznego jest zaprojektowanie i implementacja autorskiego systemu informatycznego, wspomagającego rolnika w zarządzaniu gospodarstwem i monitoringu upraw. Opracowane rozwiązanie to aplikacja webowa integrująca warstwę analityczną (język Python, algorytm DBSCAN) z warstwą prezentacji i logiki biznesowej (.NET). System umożliwia automatyczne pobieranie danych satelitarnych, ich przetwarzanie do postaci map stref zagrożenia oraz wizualizację wyników. Istotnym i niezbędnym elementem jest również moduł cyfrowego odwzorowania struktury przestrzennej gospodarstwa, umożliwiający

użytkownikowi precyzyjne definiowanie granic pól uprawnych na interaktywnych mapach. Finalny produkt dostarcza rolnikowi gotowe narzędzie do precyzyjnej oceny kondycji roślin i podejmowania decyzji agrotechnicznych, intuicyjne w użytkowaniu, o wszechstronnym zastosowaniu i możliwościach rozwoju.

3 Automatyzacja i optymalizacja procesów produkcji w rolnictwie:

Poniższy rozdział stanowi wprowadzenie do zagadnień objętych tematem pracy. Opisane są w nim zwięźle tematyka rolnictwa precyzyjnego oraz miejsce, jakie zajmują w nim sztuczna inteligencja oraz bazy danych.

3.1 Charakterystyka współczesnego rolnictwa precyzyjnego:

W dokumencie Scientific Foresight Study przygotowanym dla Parlamentu Europejskiego, koncepcja ta została zdefiniowana w następujący sposób:

Rolnictwo precyzyjne to koncepcja nowoczesnego prowadzenia gospodarstwa rolnego z wykorzystaniem technik cyfrowych do monitorowania i optymalizacji procesów produkcji rolnej. Np. zamiast stosowania nawozów w takiej samej ilości na całym areale (...) dzięki rolnictwu precyzyjnemu można zmierzyć różnice w warunkach panujących na danym polu i odpowiednio dostosować strategię w zakresie nawożenia lub zbiorów. [6]

Współczesne rolnictwo precyzyjne opiera się na zestawie zaawansowanych technologii, takich jak systemy nawigacji satelitarnej GPS/GNSS umożliwiające prowadzenie maszyn z wysoką dokładnością, narzędzia GIS wykorzystywane do tworzenia map zmienności przestrzennej oraz szeroka gama czujników rejestrujących parametry gleby, wilgotność, temperaturę czy warunki pogodowe. Istotną rolę odgrywają także metody teledetekcji, w tym obrazowanie satelitarne (np. z programu Copernicus, Planet) oraz dane pozyskiwane z dronów, które umożliwiają monitorowanie kondycji upraw, stanu zdrowotnego roślin czy dynamiki zmian zachodzących w glebie. Obrazowanie wielospektralne pozwala na obliczanie wskaźników kondycji roślinności, takich jak NDVI, kluczowy w ocenie ich zdrowia i ustalaniu dawek nawozów. Dzięki integracji

tych technologii możliwe jest prowadzenie zabiegów w optymalnych warunkach czasowych i przestrzennych, co pozytywnie wpływa na wydajność oraz stabilność produkcji. Uzyskana optymalizacja zasobów sprzyja wzrostowi produkcji żywności przy jednoczesnym minimalizowaniu kosztów środowiskowych, co jest pożądane w szybko rozwijającym się świecie, z szybko rosnącą populacją i wciąż dużymi obszarami zagrożonymi głodem i nieurodzajem [7].

Korzyści wynikające ze stosowania rolnictwa precyzyjnego mają charakter zarówno ekonomiczny, jak i środowiskowy. PA pozwalają na redukcję kosztów poprzez ograniczenie zużycia nawozów mineralnych, środków ochrony roślin, wody oraz paliwa. Można tu przytoczyć choćby cytaty: „(...) korzyści ze stosowania rozwiązań PLF i PA przekładają się na wielkości fizyczne, jak zmniejszenie zużycia paliwa o 10%, ograniczenie kosztów ochrony upraw o 30%, czasu zabiegów agrotechnicznych o 6 % i o 40% obsługi w chowie zwierząt. Na skutek wykorzystania PA koszty nawożenia mogą spaść nawet o 0,5–1,66 euro/m² (...)” [7]. Z drugiej strony precyzyjne dawkowanie środków produkcji prowadzi do zmniejszenia presji na środowisko naturalne, ograniczając ryzyko nadmiernej eutrofizacji wód, degradacji gleby czy emisji związków azotu do atmosfery.

W literaturze przedmiotu podkreśla się, że rolnictwo precyzyjne (zwane też Rolnictwem 3.0) stanowi fundament szerszej transformacji określanej mianem Rolnictwa 4.0, które polega na zwiększeniu produktywności i wydajności sektora rolniczego poprzez odpowiednie wykorzystanie i przetwarzanie informacji w sieci. Rolnictwo 4.0 integruje technologie PA, inteligentnego rolnictwa (Smart Agriculture, SA) oraz zmniejszonego wpływu na środowisko. Istotnym elementem tego zagadnienia jest szerokie wykorzystanie sztucznej inteligencji, uczenia maszynowego i Internetu Rzeczy (IoT), a więc sieci połączonych ze sobą urządzeń (takich jak sensory, maszyny czy drony), które komunikują się, zbierają dane o środowisku fizycznym i wchodzą z nim w interakcje za pośrednictwem wbudowanej technologii, bez konieczności bezpośredniej ingerencji człowieka. Wynikiem tego jest obustronna wymiana danych, w przeciwieństwie do najczęściej jednostronnej w SA, po którym następuje czas na ręczną odpowiedź. Rolnictwo 4.0 zaś toruje drogę do Rolnictwa 5.0, rozwiniętego o potężne modele sztucznej inteligencji, pozwalające na

bezpośrednią kooperację ludzi i maszyn , a więc wykorzystanie na szeroką skalę operacji bezzałogowych i automatycznych procesów decyzyjnych [8]. W tym ujęciu rolnictwo precyzyjne nie jest jedynie zestawem abstrakcyjnych narzędzi, lecz kluczowym etapem cyfryzacji rolnictwa, umożliwiającym jego dalszy rozwój w kierunku zrównoważonego, opartego nie tylko na pracy człowieka czy maszyny, ale także komputerów oraz innych zdobyczy XXI wieku.

3.2 Wyzwania w procesach produkcyjnych gospodarstw rolnych

Współczesne gospodarstwa rolne mierzą się z narastającą złożonością produkcji, wynikającą z globalnych zmian klimatycznych, presji ekonomiczno-prawnej i ograniczeń zasobowych. Jednym z fundamentalnych problemów jest niejednorodność warunków w obrębie pojedynczego pola uprawnego, co sprawia, że tradycyjne, ujednolicone metody agrotechniczne oparte na uśrednianiu i traktowaniu równo całego obszaru pola są niewystarczające i prowadzą do marnotrawstwa zasobów. Niezależnie od sposobu gospodarowania uprawą, z natury należy założyć się pewien stopień zmienności użyźnienia bądź wilgotności gleby, co wymaga pomiaru warunków na możliwie małym obszarze pola. Tymczasem wytypowanie jednej dawki nawozu na całe pole może doprowadzić do sytuacji, w której niektóre obszary dostaną jej za mało, podczas gdy inne - zupełnie niepotrzebną ilość. Wynikiem tego są wahania w plonowaniu w całym obszarze gospodarstwa.

Kolejnym, coraz mocniej widocznym wyzwaniem jest rosnąca zmienność klimatyczna i występowanie ekstremalnych zjawisk naturalnych, takich jak susze, ulewę czy gradobicia, które mają bezpośredni, negatywny wpływ na produkcję rolną. Warunki pogodowe mogą znacznie zakłócać automatyczne prowadzenie upraw [9], stąd konieczna jest ciągła weryfikacja ich stanu i reagowanie, nie tylko szybko, ale i z precyzją. Rosnąca częstość występowania skrajnych temperatur czy wzrost zasolenia wód powierzchniowych i gruntowych wywiera negatywny wpływ na wzrost i rozwój roślin. Utrzymanie możliwie najlepszych warunków

wzrostu roślin wymaga szybkiej i trafnej diagnozy, a także odpowiednich predykcji co do przyszłego stanu upraw [10].

Zarządzanie nowoczesnym gospodarstwem wymaga integracji danych z wielu, często niekompatybilnych, źródeł (np. satelity, drony, czujniki, współrzędne maszyn), co prowadzi do ogromnej ilości danych – Big Data – trudnej do przetworzenia bez zaawansowanych systemów informatycznych i analitycznych. Masowe zasypanie odbiorcy surowymi danymi bez obróbki czy przystępnej wizualizacji prowadzi do powstania bałaganu informacyjnego, uniemożliwiającego uruchomienie jakichkolwiek działań [9]. Wiele danych zbieranych w rolnictwie jest też niekompletnych lub obarczonych szumem, dlatego istnieje potrzeba stworzenia metod, które będą w stanie pracować z dużymi zbiorami niekompletnych lub niskiej jakości danych [10]. Wyzwania te nie są jedynie problemami operacyjnymi, ale mają wymiar strategiczny i technologiczny. Podstawowym ograniczeniem we wdrażaniu nowoczesnych systemów jest wysoki koszt inwestycji, także samych narzędzi cyfrowych, który jest nieopłacalny dla małych i średnich gospodarstw. Ponadto powstaje potrzeba zaznajomienia rolnika z technologiami cyfrowymi, równocześnie maksymalnie upraszczając ich interfejs, zmniejszając próg wejścia [7].

W kontekście powyższych problemów, istnieje wyraźna potrzeba stosowania zaawansowanych, zintegrowanych systemów informatycznych, które, wykorzystując sztuczną inteligencję i solidne bazy danych, będą w stanie przekształcić strumień Big Data w precyzyjne i jasne decyzje, optymalizując koszty, minimalizując straty i zwiększając wydajność, a przy tym pozostając prostymi w użyciu.

3.3 Trendy i kierunki rozwoju digitalizacji rolnictwa

Cyfryzacja rolnictwa znajduje się obecnie w fazie dynamicznej transformacji, ewoluując od etapu gromadzenia i powolnego przetwarzania danych (Rolnictwo 3.0) w kierunku w pełni zintegrowanych, autonomicznych systemów decyzyjnych, określanych (Rolnictwa 5.0) [8]. Dominującym trendem jest odchodzenie od izolowanych rozwiązań technologicznych na rzecz całościowych ekosystemów, w których Sztuczna Inteligencja przejmuje rolę aktywnego zarządcy procesów w gospodarstwie

[10]. Kluczowym kierunkiem rozwoju jest integracja Internetu Rzeczy z zaawansowaną analityką Big Data, co pozwala na dokładne odwzorowanie gospodarstwa w przestrzeni wirtualnej (wpisujące się w koncept Cyfrowego Bliźniaka - Digital Twins), umożliwiające symulację scenariuszy i optymalizację decyzji w czasie rzeczywistym [1]. W obszarze przetwarzania danych, szczególnie w systemach sterowania czasu rzeczywistego następuje wyraźny zwrot ku technologiom brzegowym (Edge Computing). Polegają one na przesunięciu ciężaru obliczeń bezpośrednio do systemu urządzenia, niwelując do maksimum przesył danych na serwer. Technika ta drastycznie redukuje opóźnienia i umożliwia natychmiastową reakcję systemów autonomicznych na zmienne warunki polowe [9]. Jednocześnie, zaawansowana analityka Big Data oraz długoterminowe planowanie strategii upraw wciąż realizowane są w oparciu o architekturę chmurową (Cloud Computing), ze względu na zapotrzebowanie na dużą moc obliczeniową [1].

Istotnym trendem jest również rosnąca rola technologii Blockchain w zabezpieczaniu łańcucha wartości. Rozproszone rejestry zapewniają niepodważalność i transparentność danych np. o pochodzeniu żywności, co jest kluczowe dla budowania zaufania konsumentów oraz realizacji strategii „od pola do stołu” [7]. Blockchain umożliwia także wdrażanie tzw. inteligentnych kontraktów (smart contracts), które automatyzują rozliczenia i ubezpieczenia rolnicze w oparciu o obiektywne dane z sensorów pogodowych i satelitarnych [9]. W kontekście sprzętowym, przyszłość należy do roju małych, współpracujących ze sobą robotów, które zastąpią ciężkie maszyny, redukując problem ugniatania gleby i zwiększając elastyczność operacyjną [11]. Równocześnie obserwuje się rozwój generatywnej sztucznej inteligencji (np. modele typu ChatGPT), która wkracza do rolnictwa jako zaawansowany asystent doradczy, zdolny do syntezy wiedzy agronomicznej i dostarczania rolnikom spersonalizowanych rekomendacji w formie naturalnej konwersacji [7].

Wyzwania klimatyczne wymuszają kierunek rozwoju w stronę Rolnictwa Inteligentnego Klimatycznie (Climate Smart Agriculture), gdzie technologie cyfrowe służą nie tylko maksymalizacji plonów, ale przede wszystkim budowaniu odporności na ekstremalne zjawiska pogodowe i optymalizacji gospodarki wodnej oraz węglowej [12]. Wdrażanie tych

innowacji jest silnie wspierane politycznie, jak choćby Europejski Zielony Ład, który promuje cyfryzację jako narzędzie redukcji śladu środowiskowego rolnictwa [7]. Ostatecznie, kierunkiem rozwoju nie jest całkowita eliminacja człowieka, lecz redefinicja jego roli w systemie – z pracownika i operatora maszyny na zarządcę floty autonomicznej i analityka danych, co wymaga nowych kompetencji i adaptacji systemów edukacji rolniczej [10].

3.4 Wykorzystanie danych satelitarnych i dronowych

Współczesne systemy rolnictwa precyzyjnego w coraz większym stopniu opierają się na technologiach teledetekcyjnych, które umożliwiają bezinwazyjne pozyskiwanie informacji o stanie upraw i gleby z dystansu, wykorzystując promieniowanie elektromagnetyczne w zakresie widzialnym, podczerwonym i mikrofalowym [9]. Kluczowym źródłem tych danych są satelity obserwacyjne, które zapewniają cykliczne i wielkoskalowe obrazowanie powierzchni Ziemi. Dane satelitarne, stanowiące podstawę niniejszego projektu, oferują szereg korzyści, takich jak szeroki zasięg przestrzenny, niski koszt pozyskania danych na hektar oraz dostępność archiwów historycznych, co pozwala na analizę trendów wieloletnich [9]. Platformy takie jak Sentinel-2 (program Copernicus) czy PlanetScope dostarczają obrazów wielospektralnych, które są niezbędne do obliczania wskaźników wegetacyjnych, w tym NDVI, służących do oceny biomasy, wigoru roślin oraz prognozowania plonów. Satelitarne monitorowanie upraw pozwala na identyfikację stref o zróżnicowanym potencjale produkcyjnym, co jest podstawą do tworzenia map aplikacyjnych dla zmiennego dawkowania nawozów [7]. Ponadto, nowoczesne systemy satelitarne wykorzystywane są do szacowania szkód wywołanych przez zjawiska ekstremalne, takie jak susze czy przymrozki, a także do monitorowania wilgotności gleby [7]. Mimo swoich zalet, obrazowanie satelitarne posiada ograniczenia związane z rozdzielczością przestrzenną (zazwyczaj 10-30 m) oraz zależnością od warunków atmosferycznych, gdzie zachmurzenie może uniemożliwić pozyskanie użytecznych danych w kluczowych fazach rozwoju roślin.

Uzupełnieniem dla technologii satelitarnych są Bezzałogowe Statki Powietrzne (UAV), potocznie zwane dronami, które oferują elastyczność operacyjną i możliwość pozyskiwania danych o bardzo wysokiej rozdzielczości przestrzennej (rzędu centymetrów) [7]. Drony wyposażone w kamery RGB, multi- czy hiperspektralne są wykorzystywane do szczegółowej inspekcji upraw, wykrywania wczesnych stadiów chorób, identyfikacji chwastów oraz tworzenia precyzyjnych map numerycznego modelu terenu [10]. W przeciwieństwie do satelitów, bezzałogowe statki powietrzne mogą operować poniżej pułapu chmur. Umożliwia to pobór danych w terminach niedostępnych dla obrazowania satelitarnego, choć nadal wymaga uwzględnienia wpływu warunków oświetleniowych, odpowiadających za zanieczyszczanie finalnego obrazu różnego rodzaju artefaktami. Niski pułap lotu umożliwia ponadto precyzyjne monitorowanie zmian w obrębie pojedynczych roślin.

W praktyce najefektywniejszym podejściem jest integracja obu źródeł danych. Obrazowanie satelitarne służy do ogólnego monitorowania dużych obszarów i wstępnej identyfikacji stref problemowych, natomiast drony są wysyłane w te konkretne miejsca w celu dokonania szczegółowej diagnozy przyczyn stresu roślin [1]. Taka synergia pozwala na optymalizację kosztów monitoringu przy jednoczesnym zachowaniu wysokiej dokładności informacji niezbędnej do podejmowania odpowiednich decyzji.

3.5 Wskaźnik NDVI – teoria i zastosowania

Wskaźnik NDVI (ang. Normalized Difference Vegetation Index), czyli Znormalizowany Różnicowy Wskaźnik Wegetacji, stanowi podstawowe narzędzie w nowoczesnej teledetekcji rolniczej, służące do ilościowej oceny kondycji roślinności oraz dynamiki jej wzrostu. Podstawy funkcjonowania wskaźnika opierają się na specyficznych właściwościach optycznych chlorofilu oraz struktury komórkowej roślin. Zdrowe, aktywnie fotosyntetyzujące rośliny charakteryzują się silnym pochłanianiem promieniowania w zakresie światła widzialnego czerwonego (RED, pasmo 600–700 nm), wykorzystywanego do fotosyntezy, oraz bardzo wysokim odbiciem w zakresie bliskiej podczerwieni (NIR, pasmo 700–1300 nm), co

wynika z rozpraszania światła przez strukturę mezofilu liści [41]. Wskaźnik ten obliczany jest według wzoru 3.1.

$$NDVI = \frac{NIR-RED}{NIR+RED}, \quad (3.1)$$

a jego wartości mieszczą się w przedziale od -1 do +1. Wartości niedodatnie wskazują na brak roślinności (woda, śnieg), wartości dodatnie, bliskie zeru oznaczają gołą glebę lub skały, natomiast większe od 0, rosnące w kierunku 1, świadczą o zwiększającej się gęstości i zdrowotności biomasy roślinnej [38]. W praktyce rolniczej NDVI jest wykorzystywany jako kluczowy parametr w systemach rolnictwa precyzyjnego do monitorowania stanu upraw w czasie rzeczywistym oraz podejmowania decyzji agrotechnicznych.

Jednym z najważniejszych zastosowań jest tworzenie map aplikacyjnych dla technologii zmiennego dawkowania, w szczególności w nawożeniu azotowym. Na podstawie map zróżnicowania NDVI, generowanych z obrazów satelitarnych lub dronowych, systemy informatyczne wyznaczają strefy o odmiennej zawartości chlorofilu w roślinach, co pozwala na precyzyjne dostosowanie dawki nawozu do aktualnych potrzeb w danej części pola [7]. Wysokie wartości wskaźnika korelują z dużą zawartością azotu i biomasy, co może sugerować potrzebę redukcji nawożenia lub zastosowania regulatorów wzrostu, podczas gdy niskie wartości mogą sygnalizować niedobory składników pokarmowych, stres wodny lub występowanie chorób.

Dzięki integracji z systemami GPS i GIS, dane NDVI stanowią cyfrową warstwę informacyjną, która w połączeniu z algorytmami uczenia maszynowego umożliwia automatyczną segmentację pól i wykrywanie anomalii, które są niewidoczne dla ludzkiego oka [13]. Należy jednak pamiętać, że NDVI jest wskaźnikiem wrażliwym na wpływ tła glebowego przy niskim zwarcie łąnu. Małe rozmiary roślin powodują przyjmowanie wartości odpowiadających niezarośniętej ziemi, a więc zaniża finalny wynik. Podobnie występuje problem nasycenia przy bardzo wysokiej biomase. Rośliny o wysokiej zawartości chlorofilu powodują przyjęcie przez wskaźnik wartości maksymalnych, które nie są w stanie się zmienić, mimo potencjalnego dalszego rozwoju. Dlatego w zaawansowanych analizach często uzupełniany jest innymi indeksami,

takimi jak NDRE (Normalized Difference Red Edge), wykorzystującymi pasmo krawędzi czerwieni do precyzyjniejszej oceny gęstych upraw. Ponadto, interpretacja wyników musi uwzględniać specyfikę biologiczną uprawy, gdyż referencyjne wartości NDVI są zmienne w zależności od gatunku rośliny oraz jej aktualnej fazy fenologicznej [13].

3.6 Algorytmy uczenia maszynowego w rolnictwie

W kontekście współczesnych systemów rolnictwa precyzyjnego, termin "sztuczna inteligencja" (AI) jest nierozdzielnie związany z uczeniem maszynowym (ang. Machine Learning, ML), które stanowi jej najbardziej dynamicznie rozwijający się podzbiór. Uczenie maszynowe definiuje się jako naukę i technologię, która umożliwia komputerom uczenie się z danych i poprawę wydajności bez konieczności bycia explicite zaprogramowanym do każdego zadania [5], [9]. Algorytmy ML budują modele matematyczne oparte na danych próbnych, zwanych "danymi treningowymi", w celu dokonywania prognoz lub podejmowania decyzji. W rolnictwie algorytmy te odgrywają kluczową rolę w transformacji ogromnych zbiorów danych (Big Data), pochodzących z sensorów, satelitów i dronów, w użyteczną wiedzę agronomiczną, umożliwiając optymalizację kosztów i maksymalizację plonów/zysków [7].

Algorytmy uczenia maszynowego dzieli się zasadniczo na dwie główne kategorie: uczenie nadzorowane (supervised learning) oraz uczenie nienadzorowane (unsupervised learning). W uczeniu nadzorowanym algorytm jest trenowany na oznaczonych danych wejściowych, gdzie znany jest oczekiwany wynik (np. klasyfikacja obrazów liści jako "zdrowe" lub "chore"). Modele te są szeroko stosowane do predykcji plonów (regresja) lub identyfikacji chorób i szkodników (klasyfikacja) [9], [14]. Jednak w specyfice analizy przestrzennej pól uprawnych, gdzie często brakuje wcześniej zdefiniowanych etykiet, kluczowe znaczenie zyskuje uczenie nienadzorowane. W tym podejściu algorytm samodzielnie odkrywa ukryte struktury i wzorce w nieoznaczonych zbiorach danych [9].

Najważniejszą techniką w ramach uczenia nienadzorowanego, mającą istotne znaczenie dla rolnictwa precyzyjnego, jest grupowanie danych (klasteryzacja). Algorytmy klasteryzacji służą do segmentacji zbioru

danych na podzbiory (klastry) w taki sposób, aby obiekty wewnątrz jednej grupy były do siebie bardziej podobne niż do obiektów w innych grupach (5). W rolnictwie technika ta jest wykorzystywana do wyznaczania stref zarządzania na podstawie zmienności parametrów glebowych lub wskaźników wegetacyjnych, takich jak NDVI. Pozwala to na wyodrębnienie obszarów o specyficznej charakterystyce, np. stref o obniżonym wigorze roślin lub występowaniu stresu wodnego [7]. Wśród algorytmów grupowania wyróżnia się metody oparte na gęstości, takie jak DBSCAN (Density-Based Spatial Clustering of Applications with Noise). W przeciwieństwie do popularnego algorytmu K-średnich (K-means), metody oparte na gęstości nie wymagają wcześniejszego zdefiniowania liczby klastrów i doskonale radzą sobie z wykrywaniem obszarów o nieregularnych kształtach oraz identyfikacją punktów odstających (szumu) [15], co czyni je szczególnie przydatnymi w wykrywaniu anomalii i alarmujących stref na mapach pól uprawnych.

3.7 Rola relacyjnych baz danych w systemach rolniczych

Współczesne rolnictwo przechodzi fundamentalną transformację cyfrową, w której bazy danych przestały pełnić funkcję jedynie pasywnych archiwów, stając się centralnym elementem operacyjnym ekosystemów zarządzania gospodarstwem [9]. W Rolnictwie 4.0 systemy te muszą obsługiwać nie tylko dane statyczne, dotyczące transakcji finansowych czy informacji o uzyskanym plonie, ale przede wszystkim ciągle strumienie danych telemetrycznych, obrazy wielospektralne oraz odczyty z tysięcy punktów pomiarowych w czasie rzeczywistym [16].

Bazy danych stanowią fundament dla wdrażania sztucznej inteligencji, pełniąc funkcję hurtowni danych (Data Warehouses), w których surowe informacje są czyszczone i etykietowane, tworząc zestawy treningowe dla algorytmów uczenia maszynowego [16]. Równocześnie niezbędna pozostaje zdolność do efektywnego przetwarzania ogromnych ilości danych rastrowych (zdjęć satelitarnych, z dronów) w celu odpowiednio szybkiego pobrania danych przez system, a następnie dalszej analizy [14].

W dziedzinie tej ugruntowaną pozycję zajmują relacyjne bazy danych (RDBMS), które dzięki strukturze tabelarycznej i językowi SQL umożliwiają

precyzyjne odwzorowanie obiektów gospodarstwa oraz obsługę danych ustrukturyzowanych, takich jak ewidencja gruntów czy historia zabiegów [9]. Ich fundamentalną zaletą jest mechanizm relacji między tabelami (klucze podstawowe, obce) oraz ścisłe przestrzeganie zasad ACID (Atomicity, Consistency, Isolation, Durability) [17], co gwarantuje integralność danych i bezpieczeństwo krytycznych operacji w systemach.

Zdefiniowane powyżej wymagania spełnia system Oracle Database, reprezentujący postrelacyjny model danych (ORDBMS). Łączy on stabilność klasycznych struktur tabelarycznych z elastycznością obiektową, co pozwala na odwzorowanie chociażby ważnych w rolnictwie złożonych typów danych przestrzennych (rozszerzenie Oracle Spatial and Graph) [18]. W odróżnieniu od standardowych rozwiązań rynkowych, Oracle wykorzystuje model współbieżności MVCC (Multi-Version Concurrency Control), który eliminuje blokady między procesami odczytu i zapisu, zapewniając płynność działania nawet przy intensywnym strumieniu danych z sensorów [19]. Dodatkowo, dzięki architekturze klastrowej (RAC) i partycjonowaniu, system jest natywnie zoptymalizowany do obsługi wolumenów Big Data, co czyni go fundamentem skalowalnych platform rolnictwa precyzyjnego [20].

4 Projekt systemu do automatyzacji i analizy danych rolniczych:

Poniżej znajdują się techniczne zagadnienia dotyczące projektowanej aplikacji. Zostały przeanalizowane założenia jakie musi spełniać, a także budowa i ważniejsze użyte narzędzia, wraz z uzasadnieniem ich wyboru.

4.1 Analiza wymagań i założenia projektowe systemu:

Głównym adresatem projektowanego systemu jest współczesny rolnik, skupiający się na produkcji roślinnej, który w obliczu transformacji cyfrowej sektora poszukuje narzędzi wspomagających podejmowanie decyzji w oparciu o nowoczesne, skuteczne rozwiązania z zakresu informatyki, wyręczające żmudne ręczne analizy czy intuicję. Podstawowym wymaganiem użytkownika jest dostęp do zintegrowanej platformy, która łączy dane z różnorodnych systemów, przede wszystkim skany i zdjęcia pól uprawnych w jednym, czytelnym interfejsie graficznym, eliminując konieczność ręcznego analizowania informacji z wielu źródeł. Użytkownik oczekuje możliwości precyzyjnego odwzorowania struktury swojego gospodarstwa, pozwalającej na większą kontrolę i centralizację zarządzania. Szczególnie ważna jest funkcjonalność odwzorowywania pól, fundament dla późniejszych analiz zdjęć satelitarnych [7].

Kluczowym wymaganiem funkcjonalnym, wynikającym z potrzeby optymalizacji produkcji i redukcji kosztów, jest automatyzacja analizy kondycji roślin. Rolnicy zgłaszają zapotrzebowanie na narzędzia umożliwiające bezinwazyjny monitoring stanu upraw, na przykład wykorzystując wskaźnik NDVI. Użytkownik nie oczekuje jednak dostępu do surowych, numerycznych danych spektralnych, lecz do przetworzonej informacji w formie mapy zmienności pola, która wizualizuje strefy o zróżnicowanym potencjale plonotwórczym, czy to z powodu braku związków azotu czy suszy [9]. W tym kontekście, istotnym wymaganiem jest implementacja algorytmów, które autonomicznie wskażą obszary zagrożone, wspierając użytkownika w szybkim reagowaniu na zagrożenia. System powinien posiadać dostęp do szerokiej gamy skutecznych, zoptymalizowanych modeli z zakresu sztucznej inteligencji również w kierunku przyszłego rozwoju, biorąc bowiem pod uwagę szybki rozwój

samemu SI jak i Rolnictwa 5.0 można przewidywać pojawienie się nowych rozwiązań w rolnictwie, które będzie należało zaimplementować [9].

Z perspektywy użyteczności, system musi niwelować bariery techniczne i kompetencyjne, które często hamują wdrażanie innowacji w rolnictwie. Wymaga się, aby interfejs aplikacji był intuicyjny i nie wymagał od rolnika zaawansowanej wiedzy informatycznej czy umiejętności programowania, co jest zgodne z postulatami dotyczącymi projektowania systemów wspomaganie decyzji [7]. Ponadto istotnym jest zrealizowanie potrzeby mobilności i zdalnego zarządzania gospodarstwem, co pozwalałoby na monitorowanie upraw z dowolnego miejsca [10]. Użytkownik wymaga, aby system zapewniał bezpieczeństwo gromadzonych danych historycznych o polach, traktując je jako wrażliwe zasoby przedsiębiorstwa rolnego, co wymusza zastosowanie w projekcie bezpiecznych mechanizmów autoryzacji i trwałego przechowywania danych w bazie [7].


Poza samymi funkcjonalnościami nie można zapomnieć o wydajności, szczególnie w kwestii operacji na danych rastrowych. Rolnikowi zależy na szybkich wynikach analizy, a więc sprawnemu pobieraniu zapisanych zdjęć, czasami parę razy w niewielkim odstępie czasu. Istotnym jest więc zastosowanie rozwiązań nie tylko optymalizujących samo przechowywanie rastrów, ale również dostęp do nich oraz szybki przesył rezultatów do odbiorcy [9].

Całość wymagań dopełnia konieczność zapewnienia wysokiej niezawodności i odporności systemu na awarie. Szczególnym jest zagwarantowanie integralności danych na poziomie bazy danych poprzez ścisłe przestrzeganie standardu transakcyjnego ACID. Zabezpiecza to system przed utratą spójności w przypadku nieprzewidzianych przerw w działaniu infrastruktury lub błędów krytycznych [17]. Równie istotne jest zaimplementowanie mechanizmów obsługi wyjątków w warstwie aplikacji, co chroni użytkownika końcowego przed skutkami błędów i zapewnia stabilność procesu decyzyjnego.

4.2 Specyfikacja funkcjonalna

Głównym klientem inicjującym większość procesów jest rolnik – uwierzytelniony użytkownik systemu, posiadający uprawnienia do

zarządzania gospodarstwem oraz wykonywania analiz satelitarnych. Diagram przypadków użycia (Rysunek 4.1) prezentuje specyfikację projektowanego systemu z perspektywy głównego użytkownika oraz jego interakcje z otoczeniem systemowym.



Rysunek 4.1 - Diagram przypadków użycia

Funkcjonalność aplikacji została logicznie podzielona na cztery główne moduły. Pierwszym z nich jest Autoryzacja i Konto, odpowiadający za bezpieczeństwo i personalizację. Obejmuje procesy rejestracji (zintegrowanej z weryfikacją adresu e-mail poprzez zewnętrzny serwer SMTP) oraz logowania. Warto zwrócić uwagę na przypadek użycia „Usunięcie konta”, który ze względów bezpieczeństwa zawiera relację <<include>> do „Potwierdzenia hasłem”, wymuszając na użytkowniku ponowną autoryzację przed wykonaniem tej krytycznej operacji. Użytkownik ma również możliwość konfiguracji ustawień, takich jak personalizacja motywu czy zmiana danych osobowych.

Kolejny pakiet to Zarządzanie (GIS), który stanowi trzon funkcjonalności systemu w zakresie modelowania wirtualnego gospodarstwa. Główny proces „Zarządzanie Gospodarstwem” jest rozszerzany (<<extend>>) o operacje CRUD, takie jak dodawanie, usuwanie pól czy modyfikacja lokalizacji gospodarstwa (w celu pobierania pogody dla miejsca zamieszkania). Szczególną uwagę należy zwrócić na proces „Definiowania granic pola”, który automatycznie inicjuje „Pobranie danych glebowych”. System, wykorzystując centroid zdefiniowanej geometrii, łączy się z zewnętrzną usługą Geoportal (GUGiK WMS) w celu pobrania danych dotyczących gleby w tym miejscu, zwalniając użytkownika z konieczności ręcznego ich wprowadzania. Podobnie proces „Edycji danych uprawy” (zmiana daty siewu, nazwy rośliny) automatycznie wymusza „Estymację fazy wzrostu”, realizowaną przez logikę biznesową bazy danych.

Trzecim obszarem jest Analiza i Historia, czyli moduł zaawansowanego przetwarzania obrazu. Użytkownik może importować pliki GeoTIFF, co jest warunkiem koniecznym (<<include>>) dla „Generowania mapy NDVI” i przeprowadzenia dalszych analiz. W ramach analizy kondycji roślin, system udostępnia funkcję „Klastrowania anomalii (DBSCAN)”, która jest opcjonalnym rozszerzeniem podstawowej mapy wskaźnikowej. Moduł zapewnia również dostęp do historii skanów pola, umożliwiając przeglądanie obrazów rgb, map NDVI oraz usuwanie zbędnych rekordów. Ostatnim elementem jest Panel aktualności – rozwojowy moduł informacyjny, umożliwiający sprawdzenie bieżących warunków meteorologicznych poprzez integrację z zewnętrznym interfejsem METEO API (Open-Meteo).

Diagram uwzględnia również kluczowe Systemy Zewnętrzne (Aktorów Systemowych), z którymi aplikacja integruje się w celu realizacji swoich zadań. Serwis Geoportal (GUGiK WMS) stanowi źródło oficjalnych danych o klasach glebowych, natomiast Serwis Mapowy (OpenStreetMap) dostarcza podkład mapowy niezbędny do wizualnego zarządzania gospodarstwem. Serwis E-mail (SMTP) obsługuje wysyłkę tokenów weryfikacyjnych przy rejestracji, a METEO API dostarcza dane pogodowe. Zastosowane relacje <<include>> wskazują na funkcjonalności niezbędne i wykonywane automatycznie w ramach danego procesu, natomiast relacje

<<extend>> obrazują opcjonalne ścieżki działania, zależne od decyzji użytkownika (np. usunięcie pola, personalizacja interfejsu).

W celu zachowania przejrzystości diagramu zrezygnowano z prezentacji połączeń przypadków użycia z bazą danych. Jest ona używana przy większości z powyższych funkcjonalności i próba włączenia jej do diagramu znacząco obniżyłaby czytelność specyfikacji.


4.3 Architektura systemu

Opracowany system informatyczny opiera się na wielowarstwowej architekturze, która jest standardem w projektowaniu nowoczesnych aplikacji webowych. Taka struktura zapewnia logiczną separację warstwy prezentacji, logiki biznesowej oraz dostępu do danych, co jest kluczowe dla skalowalności, łatwości konserwacji oraz bezpieczeństwa przetwarzanych informacji [21]. Umożliwia ona integrację różnych, odrębnych komponentów technologicznych – od relacyjnej bazy danych Oracle, poprzez backend w technologii ASP.NET, aż po zaawansowane moduły analityczne oparte na języku Python – w spójne środowisko operacyjne. System działa w modelu klient-serwer, gdzie centralny serwer przetwarza żądania i zarządza danymi, a interfejs użytkownika jest dostarczany do przeglądarki internetowej klienta. Wpisuje się to w trend chmurowego udostępniania usług rolniczych i zapewnia dostępność systemu i, co za tym idzie, wszystkich danych użytkownika, z dowolnego urządzenia podłączonego do sieci [7].

W realizacji projektu przyjęto hierarchiczny model komunikacji, w którym każda warstwa posiada ściśle zdefiniowaną odpowiedzialność. Za interfejs aplikacji, komunikujący się z użytkownikiem i przyjmujący jego polecenia odpowiada połączenie języków HTML, CSS oraz JavaScript. Kolejnym punktem wejścia dla żądań klienta w backendzie systemu jest warstwa API (Kontrolery). Uruchamiają one konkretne metody warstwy logiki biznesowej (Serwisów), które wykonują kluczowe operacje przetwarzania danych - integrują obliczenia, zarządzają autoryzacją oraz komunikują się z klasami pomocniczymi oraz systemami zewnętrznymi (np. Geoportal). Istotnym elementem projektu jest wyizolowanie operacji na bazie danych do osobnej warstwy dostępu (DAL – Data Access Layer).

Całość dopełnia bezpośrednia integracja środowiska uruchomieniowego Python wewnątrz procesu aplikacji. Pozwala ona wykorzystać proste w implementacji i potężne w wydajności algorytmy z obszarów AI, zachowując budowę i wydajność aplikacji ASP.NET.

Szczegółowy schemat komponentów (pomijając klasy i metody pomocnicze) oraz przepływ danych pomiędzy poszczególnymi warstwami systemu przedstawiono na rysunku 4.2.



Rysunek 4.2 - Diagram logiki aplikacji

4.4 Warstwa frontend (HTML, CSS, JavaScript)

Warstwa prezentacji (frontend) pełni funkcję interfejsu użytkownika (UI), odpowiadając za bezpośrednią interakcję rolnika z systemem oraz wizualizację wyników dostarczanych przez backend. Została ona zaimplementowana w oparciu o standardowe technologie webowe: język HTML w wersji 5, definiujący strukturę treści, kaskadowe arkusze stylów CSS w wersji 3 odpowiadające za warstwę wizualną i responsywność, oraz język JavaScript, zapewniający dynamiczną interaktywność aplikacji. Świadome użycie natywnych arkuszy stylów, z pominięciem gotowych frameworków pokroju Bootstrapa, pozwoliło na stworzenie niestandardowego układu graficznego oraz zachowanie pełnej kontroli nad

kodek, eliminując problemy związane z importem zbędnych bibliotek. Nieskomplikowana struktura dziedziczenia stylów uzasadniła również rezygnację z preprocesorów takich jak SASS czy SCSS. Zastosowanie języka JavaScript umożliwiło natomiast ścisłą separację warstwy prezentacji od logiki serwerowej, co pozwala na niezależną przebudowę warstwy biznesowej bez ryzyka utraty kompatybilności z interfejsem. Wszystkie wykorzystane technologie, stanowiące ugruntowane standardy programistyczne [22], zostały zintegrowane w jedną, spójną warstwę prezentacji. Charakteryzuje się ona przejrzystą architekturą, co ułatwia programiście szybkie wdrożenie i zrozumienie struktury projektu [21].

W kontekście rolnictwa precyzyjnego rola warstwy frontendowej jest kluczowa, ponieważ musi ona przetransformować surowe dane numeryczne i rastrowe w czytelną formę graficzną, przystępną dla użytkownika końcowego. Frontend komunikuje się z warstwą backendową za pośrednictwem protokołu HTTP, wysyłając zapytania i odbierając dane (zazwyczaj w formacie JSON), które są następnie odczytywane bezpośrednio w przeglądarce. Proces projektowania tej warstwy uwzględniał specyficzne wymagania sektora rolniczego, kładąc nacisk na optymalizację i użyteczność, aby zaawansowane funkcje analityczne były zrozumiałe i dostępne również dla osób słabo radzących sobie z obsługą urządzeń cyfrowych.

4.5 Warstwa backend (ASP.NET / C#)

Warstwa backendowa, zrealizowana w oparciu o framework ASP.NET oraz obiektowy język C#, pełni funkcję centralnego węzła logicznego i integracyjnego w zaprojektowanym systemie. Rola tej warstwy odpowiada za zarządzanie urządzeniami, nadzoruje przepływ danych oraz obsługuje logikę aplikacji. Backend działa jako serwer aplikacji, który udostępnia interfejsy programistyczne (API) dla warstwy frontendowej, umożliwiając bezpieczną wymianę informacji w formacie JSON oraz realizację kluczowych procesów biznesowych, takich jak uwierzytelnianie użytkowników czy zarządzanie kontami. Ze względu na konieczność przetwarzania dużych wolumenów danych przestrzennych i obrazowych (Big Data) pochodzących z monitoringu upraw, została wykorzystana

technologia ASP.NET. Zapewnia ona niezbędną wydajność, skalowalność oraz stabilność środowiska uruchomieniowego [23].

Warstwa ta odpowiada również za możliwości komunikacji z pozostałymi modułami systemu: zarządza połączeniami z bazą danych Oracle poprzez interfejs ADO.NET, zapewniając szybki dostęp do składowanych danych, a także inicjuje procesy analityczne realizowane przez skrypty Python, integrując wyniki tych operacji z głównym przepływem danych w aplikacji. Dzięki zastosowaniu architektury wielowarstwowej backend pozwala na elastyczne dołączanie nowych modułów funkcjonalnych lub zewnętrznych źródeł danych w przyszłości [21], co jest istotne dla systemów rolnictwa precyzyjnego – zagadnienia o wielkim potencjale rozwoju [7].

4.6 Integracja z Oracle przez ADO.NET

Integracja warstwy aplikacji z relacyjną bazą danych Oracle została zrealizowana przy wykorzystaniu technologii ADO.NET, która stanowi podstawowy mechanizm dostępu do danych w ekosystemie .NET. W warstwie dostępu do danych wykorzystano sterownik Oracle Data Provider for .NET (ODP.NET) w wersji Managed. Dzięki pełnej integracji ze środowiskiem .NET Core, rozwiązanie to eliminuje konieczność instalacji ciężkiego oprogramowania klienckiego (Oracle Client) na serwerze. Znacząco upraszcza to proces wdrażania aplikacji w infrastrukturze chmurowej oraz zapewnia optymalną wydajność transmisji danych [24]. Kluczowym elementem tej integracji jest mechanizm zarządzania połączeniami. W systemach webowych obsługujących wielu użytkowników jednocześnie, takich jak projektowana platforma dla rolnictwa precyzyjnego, wielokrotne nawiązywanie fizycznych sesji z bazą danych jest procesem kosztownym czasowo i zasobowo. ADO.NET automatycznie utrzymuje pulę aktywnych połączeń, przydzielając je dynamicznie do napływających żądań HTTP, co drastycznie redukuje opóźnienia i zwiększa skalowalność systemu w obliczu rosnącego wolumenu danych telemetrycznych [24].

Wymiana danych realizowana jest za pomocą obiektów klasy OracleCommand, które umożliwiają wykonywanie poleceń SQL oraz wywoływanie procedur PL/SQL. Zastosowanie procedur składowanych

pozwała na bardziej zaawansowane zapytania, uwzględniając szczególnie pozyskiwanie danych typu SDO_GEORASTER. W celu zapewnienia bezpieczeństwa informacji, wszystkie zapytania do bazy danych są w pełni sparametryzowane. Takie podejście skutecznie neutralizuje ryzyko ataków typu SQL Injection [17], które stanowią jedno z głównych zagrożeń dla systemów gromadzących wrażliwe dane o produkcji rolnej. Do pobierania danych wykorzystano obiekt OracleDataReader, który oferuje szybki, jednokierunkowy strumień odczytu, minimalizując obciążenie pamięci operacyjnej serwera [24]. Całość interakcji z bazą danych objęta jest obsługą wyjątków oraz transakcyjnością, co gwarantuje atomowość operacji i spójność danych (ACID) nawet w przypadku wystąpienia błędów w trakcie zapisu złożonych struktur informacji o gospodarstwie.

4.7 Zewnętrzna baza danych Oracle i środowisko SQL Developer

W architekturze opracowanego systemu, warstwa trwałości danych została zaimplementowana w oparciu o zewnętrzną instancję post-relacyjnej bazy danych Oracle Database, która pełni rolę centralnego repozytorium dla wszystkich informacji składowanych w ramach platformy. Decyzja o separacji serwera bazy danych od serwera aplikacji wynika z potrzeby zapewnienia wysokiej wydajności, skalowalności oraz bezpieczeństwa zgromadzonych zasobów. Cechy te są standardem w profesjonalnych systemach informatycznych dla rolnictwa, obsługujących duże zbiory danych (Big Data). Ponadto zewnętrzna baza danych nie jest uzależniona od kodu programu i można nią zarządzać bezpośrednio. Zarządzanie strukturą bazy, tworzenie obiektów oraz manipulacja danymi realizowane są za pośrednictwem zintegrowanego środowiska programistycznego Oracle SQL Developer. Narzędzie to, działające po stronie klienta administracyjnego, umożliwia graficzną obsługę schematu bazy danych, wykonywanie zapytań SQL, debugowanie procedur składowanych PL/SQL oraz monitorowanie wydajności instancji w czasie rzeczywistym [26].


Kluczowym aspektem zastosowania Oracle Database w projekcie jest wykorzystanie jej natywnych możliwości w zakresie obsługi danych

przestrzennych (Oracle Spatial), co jest niezbędne do przechowywania zdjęć satelitarnych pól uprawnych, jako typ SDO_GEORASTER. Jest to rozszerzenie bardzo skuteczne, optymalnie składujące przechowywane rastry, pozwalające na elastyczny do nich dostęp oraz oferujące potężne narzędzia w obliczy przyszłego rozwoju aplikacji [27]. Natomiast definicje granic działek (wielokąty, polygony), rysowane przez użytkownika na interfejsie mapowym i zawierające się w typie GEOJSON, są składowane w bazie w kolumnach typu JSON. Jest to optymalniejsze rozwinięcie typu CLOB, ze względu na szybki dostęp oraz łatwy odczyt [28].

Komunikacja z zewnętrznym serwerem bazy danych realizowana jest za pośrednictwem protokołu TCP/IP. Baza nasłuchuje na określonym porcie, aplikacja zaś za pomocą Connection String nawiązuje z nią połączenie. Dzięki zastosowaniu Oracle SQL Developer, proces wdrażania zmian w strukturze bazy (migracje) oraz optymalizacja zapytań mogą być przeprowadzane w sposób kontrolowany i audytowalny, co zapewnia stabilność całego ekosystemu informatycznego [26].

4.8 Projekt bazy danych:

Na rysunku 4.3 umieszczono diagram logiczny bazy danych, obrazujący strukturę logiczną przechowywanych danych. Centralnym punktem systemu jest tabela FIELDS (Pola), która łączy profil użytkownika USERS z danymi analitycznymi SATELLITE_SCANS oraz słownikami agrotechnicznymi.



Rysunek 4.3 - Diagram logiczny bazy danych

Struktura fizyczna bazy danych składa się z następujących kluczowych tabel:

- **USERS** (Użytkownicy). Tabela przechowuje dane użytkownika, w tym uwierzytelniające oraz preferencje. Hasła nie są przechowywane jawnym tekstem, lecz w kolumnie PASSWORD_HASH (hash Argon2), co zapewnia bezpieczeństwo zgodne z aktualnymi standardami. Kolumny FARM_LATITUDE i FARM_LONGITUDE przechowują współrzędne geograficzne bazy gospodarstwa, wykorzystywane przez moduł pogodowy. VERIFICATION_TOKEN przechowuje token dla jeszcze nie zweryfikowanych użytkowników. IS_VERIFIED przyjmuje wartość 1 dla zweryfikowanych użytkowników (potwierdzony adres email), 0 w przeciwnym wypadku.

- **FIELDS** (Pola uprawne). Jest to główna tabela operacyjna systemu. Granice pola przechowywane są w kolumnie GEO_JSON typu JSON (będący optymalniejszym wyborem nad CLOB - Character Large Object). W przypadku danych zdecydowano się na format JSON zamiast natywnego typu SDO_GEOMETRY dla geometrii wektorowej, aby uprościć integrację

z warstwą frontendową (biblioteka Leaflet.js) i uniknąć kosztownej konwersji obiektów po stronie serwera aplikacji. Tabela posiada klucze obce do słowników glebowych oraz tabeli roślin i cykli wzrostu, co pozwala na precyzyjne profilowanie charakteru uprawy, jej stanu, daty wzrostu, bez wielokrotnego zapisywania pełnych nazw.

- SATELLITE_SCANS (Skany satelitarne). Tabela ta wykorzystuje zaawansowany typ danych obiektowych Oracle: MDSYS.SDO_GEORASTER. W odróżnieniu od klasycznego przechowywania plików graficznych jako BLOB, typ GeoRaster umożliwia przechowywanie danych wielowymiarowych (wielu pasm spektralnych) wraz z ich metadanymi bezpośrednio w strukturze bazy danych. Kolumna BBOX przechowuje informacje o położeniu zdjęcia w przestrzeni. Format JSON ponownie przyspiesza pracę nad danymi na czele z szybkością odczytywania, co jest ważne przy funkcjonalności rysowania kształtu pola bezpośrednio na zdjęciu.

- SATELLITE_SCANS_RDT. Jest to tabela pomocnicza dla kolumny RASTER w SATELLITE_SCANS. Stanowi ona cechę typu MDSYS.SDO_GEORASTER, w niej przechowywane są szczegółowe dane na temat rastra, takie jak fizyczne bloki pikseli (zapisane w formacie BLOB) oraz wygenerowane poziomy piramidowania (różnych rozdzielczości). Tabela ta jest zarządzana automatycznie przez system Oracle i umożliwia tzw. *blocking*, czyli pobieranie tylko niezbędnych fragmentów obrazu bez konieczności wczytywania całego pliku do pamięci.

- Słowniki dotyczące gleb (SOIL_xxx). Przechowują one w dwóch kolumnach odpowiednio kod (maksymalnie czteroznakowy) oraz dokładną nazwę danego parametru gleby (kompleks, typ, pierwsza warstwa). Wydzielenie tych danych do osobnych tabel pozwala na uniknięcie redundancji w tabeli głównej oraz zapewnia zgodność z trzecią postacią normalną (3NF), co gwarantuje spójność danych i ułatwia ich aktualizację.

- Słowniki dotyczące roślin i ich cyklu (PLANTS, PLANT_STATES, GROWTH_CYCLES). Tabele te pełnią rolę nie tylko słownikową, ale również sterującą logiką biznesową. Tabela PLANTS przechowuje indeks rośliny oraz jej nazwę. GROWTH_CYCLES wszystkie rodzaje stopni wzrostu oraz przykładowe poziomy wskaźnika NDVI, dzielące wynik na dobry, zadowalający oraz alarmujący. PLANT_STATES łączy te tabele

przypisując każdej roślinie możliwe stopnie wzrostu skojarzone z ilością dni od siewu. Dzięki temu logika walidacji kondycji roślin jest zintegrowana ze strukturą danych.

Relacje między tabelami oparte są na kluczach obcych z wymuszeniem integralności referencyjnej (CONSTRAINT FK). Zastosowano kaskadowe usuwanie danych (w przypadku usunięcia użytkownika usuwane są jego pola, a w przypadku usunięcia pola – jego skany), co upraszcza zarządzanie cyklem życia danych.

Ze względu na specyfikę systemu przetwarzającego duże zbiory danych, zastosowano szereg mechanizmów optymalizacyjnych:

- Optymalizacja podzapytań w operacjach INSERT. W procesie dodawania nowego pola (FarmService) zastosowano technikę zagnieżdżonego zapytania SELECT ID FROM USERS wewnątrz instrukcji INSERT. Pozwoliło to na zredukowanie liczby operacji sieciowych (Round-Trips) pomiędzy aplikacją a bazą danych, eliminując konieczność oddzielnego pobierania ID użytkownika przed wykonaniem zapisu.

- Założono indeksy B-drzewa na kluczach głównych (automatycznie), kolumnach z ograniczeniem UNIQUE oraz na kluczach obcych (np. FIELDS.USER_ID, SATELLITE_SCANS.FIELD_ID). Jest to kluczowe dla wydajności operacji łączenia tabel (JOIN), które są wykorzystywane w większości widoków aplikacji.

- Schemat bazy danych zaprojektowano zgodnie z zasadami normalizacji (do trzeciej postaci normalnej – 3NF), aby wyeliminować nadmiarowość danych, przy jednoczesnym zachowaniu wydajności dla zapytań analitycznych.

- W przypadku tabeli SATELLITE_SCANS, typ MDSYS.SDO_GEORASTER wewnętrznie wykorzystuje mechanizmy blockingu i piramidowania (tworzenia miniatur o różnej rozdzielczości), co umożliwia szybki dostęp do fragmentów obrazu bez konieczności odczytu całego pliku TIFF z dysku.

- Zarządzanie dużymi obiektami (LOB). Dla kolumn wykorzystujących natywny typ danych JSON (przechowujący geometrię w formacie binarnym OSON) oraz obiektów GeoRaster, Oracle Database zarządza przestrzenią dyskową w osobnych segmentach LOB. Zapobiega to fragmentacji tabeli głównej i utrzymuje wysoką wydajność skanowania

indeksów, gdyż obszerne struktury danych są ładowane do pamięci tylko wtedy, gdy są jawnie żądane.

- Dopasowanie formatów kolumn. Aby zbędnie nie rezerwować dużych wolumenów pamięci typ każdej kolumny został odpowiednio zmodyfikowany. I tak kolumny przechowujące wartości binarne mają typ NUMBER z możliwą jedną cyfrą, w tym zeru po przecinku. Kolumny zawierające znakowe kody to typ VARCHAR2 z odpowiednią maksymalną liczbą znaków.

4.9 Warstwa analityczna Python + Python.NET

Warstwa analityczna systemu została zaprojektowana w modelu hybrydowym, wykorzystującym specyficzne zalety obu środowisk programistycznych w celu optymalizacji procesu pozyskiwania wiedzy z danych satelitarnych. W ramach przyjętego podziału zadań, wstępne przetwarzanie obrazów rastrowych oraz operacje arytmetyczne związane z obliczaniem wskaźnika NDVI realizowane są bezpośrednio w środowisku C# (ASP.NET). Jest to środowisko niezwykle efektywne, szybkość przetwarzania złożonych operacji na macierzach pikseli jest porównywalna z C++ [29]. Tak przygotowane, znormalizowane dane wegetacyjne są następnie przekazywane do modułu sztucznej inteligencji, zaimplementowanego w języku Python. Stanowi on standard w dziedzinie Data Science [30].

Integracja pomiędzy środowiskiem uruchomieniowym .NET a skryptami Pythona odbywa się za pośrednictwem biblioteki Python.NET. Umożliwia ona osadzenie silnika Pythona wewnątrz procesu aplikacji webowej i bezpośrednią wymianę struktur danych. Moduł ten odpowiedzialny jest za zaawansowaną analizę przestrzenną, wykorzystując bibliotekę scikit-learn do uruchomienia algorytmu klasteryzacji gęstościowej DBSCAN (Density-Based Spatial Clustering of Applications with Noise). Algorytm ten, na podstawie otrzymanych danych o pikselach o alarmującym poziomie NDVI, autonomicznie wyodrębnia zwarte obszary anomalii wegetacyjnych, ignorując szum pomiarowy oraz sortując klastry w zależności od średniej wartości wskaźnika. Jest to kluczowe dla

precyzyjnego wyznaczania stref wymagających interwencji agrotechnicznej [10].

Należy podkreślić, że zastosowana architektura z wykorzystaniem Python.NET ma w niniejszej pracy charakter demonstracyjny, mający na celu ukazanie możliwości połączenia zalet C# oraz Pythona. W docelowych systemach produkcyjnych, obsługujących masowy ruch i jeszcze większe zbiory danych, rekomendowanym podejściem jest separacja warstwy analitycznej w formie niezależnych mikroserwisów [31]. Architektura mikroserwisowa, komunikująca się np. poprzez REST API lub kolejki wiadomości [31], pozwoliłaby na niezależne skalowanie modułu AI, lepsze zarządzanie zasobami obliczeniowymi oraz uniknięcie blokowania głównego wątku aplikacji webowej podczas wykonywania złożonych operacji klasteryzacji.

4.10 Zewnętrzne usługi mapowe (OpenStreetMap)

W architekturze systemu, moduł GIS został zintegrowany z serwisem OpenStreetMap, który pełni funkcję zewnętrznego dostawcy podkładów mapowych. Wybór tego rozwiązania podyktowany był otwartym modelem licencyjnym ODbL (Open Data Commons Open Database License) oraz wysoką dostępnością danych topograficznych [32], co jest kluczowe w projektowaniu ekonomicznie efektywnych rozwiązań dla rolnictwa cyfrowego. W warstwie prezentacji aplikacji, kafelki mapowe (tiles) pobierane z serwerów OSM stanowią wygodną wizualizację świata, umożliwiając użytkownikowi intuicyjną lokalizację gospodarstwa oraz nawigację w obrębie interfejsu. Ważną funkcjonalnością zaimplementowaną w oparciu o to API jest narzędzie do cyfrowego wyznaczania granic pól uprawnych. Użytkownik, wspomagany przez rastrową mapę działek, korzystając z biblioteki Leaflet interaktywnie rysuje obrysy swoich pól, definiując w ten sposób ich geometrię. Służy to wyżej wspomnianej potrzebie całkowitego odwzorowania gospodarstwa w przestrzeni wirtualnej [9]. Sama biblioteka Leaflet została wybrana ze względu na jej wysoką wydajność oraz dostępność na permisywnej licencji BSD 2-Clause [33].

Zastosowanie powyższych narzędzi nie ogranicza się tylko do warstwy wizualnej. Dzięki Leaflet możliwe jest uzyskanie współrzędnych środka figury pola, potrzebnych do oszacowania składu gleby, we współpracy z serwisem Geoportal. Każde dodane pole staje się interaktywną częścią interfejsu mapy, z możliwością podglądu informacji czy całkowitego usunięcia wszystkich powiązanych z nim informacji.

Niemniej ważną jest funkcjonalność ustawienia położenia gospodarstwa, również sprawowana przez OpenStreetMap. Ta czynność stanowi podstawę do oceny pogody w regionie pracy rolnika oraz ważny element przyszłego całkowitego sprzężenia z Internetem Rzeczy (lokalizacja każdego urządzenia, pomiary odległości od gospodarstwa etc.).

4.11 Integracja z usługami publicznymi Geoportal

Tworzenie zarysów pól oraz pobieranie kluczowych informacji o ich terenie wsparto danymi oficjalnych rejestrów państwowych. W tym celu system został zintegrowany z infrastrukturą Geoportalu Krajowego (Główny Urząd Geodezji i Kartografii). Integracja ta realizowana jest dwutorowo, wykorzystując potencjał zarówno warstwy prezentacji, jak i logiki biznesowej, w celu uczynienia aplikacji bardziej intuicyjną przy jednoczesnym zachowaniu wiarygodności danych.

W warstwie frontendowej (JavaScript), podczas procesu definiowania granic nowego pola, system komunikuje się z usługami WMS (Web Map Service) Geoportalu. Pozwala to na nałożenie na podkład mapowy rastrowej warstwy ewidencyjnej granic działek w czasie rzeczywistym. Dzięki temu użytkownik, korzystając z narzędzi do rysowania (Leaflet), może precyzyjnie obrysować granice swojego gospodarstwa, opierając się na oficjalnym obrysie geodezyjnym, a nie tylko na własnej intuicji i szczątkowych informacjach mapy OpenStreetMap.

Pozyskanie rastrowej warstwy działek jest oparte na usłudze Krajowej Integracji Ewidencji Gruntów (KIEG), udostępnianej publicznie przez Główny Urząd Geodezji i Kartografii (GUGiK) w otwartym standardzie OGC Web Map Service. Dostęp do danych o geometrii działek ewidencyjnych realizowany jest na podstawie znowelizowanej ustawy Prawo geodezyjne i kartograficzne. Zgodnie z art. 40a ust. 2 pkt 1, dane dotyczące geometrii

działek ewidencyjnych i budynków są udostępniane nieodpłatnie i mogą być wykorzystywane do dowolnych celów (w tym komercyjnych) bez konieczności składania wniosków czy uzyskiwania dodatkowych licencji, pod warunkiem wskazania źródła pochodzenia danych [34].

Druga część integracji dotyczy pozyskiwania atrybutów glebowych. Po zatwierdzeniu geometrii przez użytkownika, współrzędne centroidu pola są przetwarzane w celu ustalenia klasy bonitacyjnej. Przekazywane są one do warstwy backendowej (FarmService), która wykonuje zapytanie do API Geoportalu. Odpowiedź serwera (w formacie XML) zawiera pełny zestaw atrybutów opisowych dla danego punktu, z którego do bazy danych zapisywane są wyłącznie trzy kluczowe parametry agrotechniczne (kompleks, typ gleby, podłoże pierwsze).

Dane o strukturze glebowej (kompleksy przydatności rolniczej) pobierane są z usługi WMS „Mapa Glebowo-Rolnicza. Jest to cyfrowe opracowanie map w skali 1:5000, udostępniane oficjalnie przez GUGiK w ramach państwowej infrastruktury Geoportal.gov.pl. Możliwość nieodpłatnego wykorzystania tych zasobów w systemie, w tym do celów komercyjnych, realizowana jest na podstawie ustawy o otwartych danych i ponownym wykorzystywaniu informacji sektora publicznego [35].

4.12 Dane pogodowe OpenMeteo

Interfejs pogodowy zaimplementowano przy użyciu publicznego API serwisu Open-Meteo. Rozwiązanie to umożliwia pobieranie szczegółowych prognoz dla dowolnej lokalizacji, zdefiniowanej poprzez szerokość i długość geograficzną, co pozwala na precyzyjne dopasowanie danych do położenia gospodarstwa. Oprócz podstawowych parametrów, takich jak temperatura powietrza czy prędkość wiatru, system pobiera również znormalizowane kody pogody (wg standardu WMO), które są następnie tłumaczone we frontendzie na czytelną dla użytkownika formę graficzną. Korzystanie z zasobów Open-Meteo odbywa się na zasadach licencji Creative Commons Attribution 4.0 (CC BY 4.0) [36].

4.13 Sterownik GDAL

Do operacji na plikach graficznych i mapach w warstwie serwerowej wykorzystano bibliotekę GDAL (Geospatial Data Abstraction Library). Pełni ona rolę uniwersalnego interfejsu, który pozwala aplikacji łatwo i elastycznie odczytywać dane przestrzenne. Dzieje się to dzięki architekturze opartej na wtyczkach zwanych sterownikami (drivers) [37].

W projekcie GDAL pełni ważną funkcję przy obsłudze zdjęć satelitarnych. Zastosowano tu zaawansowany mechanizm tzw. wirtualnych plików w pamięci (VSI /vsimem/). Dzięki niemu, pobrane z satelity dane nie muszą być zapisywane na dysku twardym serwera w celu dalszej obróbki, lecz są przetwarzane bezpośrednio w szybkiej pamięci RAM. Znacząco przyspiesza to działanie aplikacji.

Dodatkowo, GDAL odpowiada za przetwarzanie surowych danych naukowych na obraz zrozumiały dla użytkownika. Kamery satelitarne rejestrują obraz w bardzo wysokiej rozpiętości tonalnej (14-bitów) oraz często w formacie float (-1..1), biblioteka przelicza te wartości na standardowy format całkowity 8-bitowy (normalizacja), a także pozwala wyciągnąć z pliku tylko te pasma kolorów (np. czerwień i podczerwień), które są potrzebne do obliczania wskaźnika zdrowia roślin (NDVI).

Biblioteka jest oprogramowaniem o otwartym kodzie źródłowym, udostępnianym na liberalnej licencji MIT [37], zezwalającej na bezpłatne kopiowanie, modyfikowanie oraz łączenie biblioteki z własnym oprogramowaniem, również o charakterze komercyjnym. Jedynym wymogiem formalnym jest zachowanie oryginalnej noty o prawach autorskich w dołączonej dokumentacji lub kodzie, co w niniejszym projekcie realizowane jest poprzez system zarządzania pakietami.

5 Implementacja aplikacji

Poniższy rozdział opisuje funkcjonowanie stworzonej aplikacji, skupiając się na najważniejszych funkcjonalnościach, takich jak zarządzanie wirtualnym gospodarstwem, import i wizualizacja danych oraz algorytm grupowania miejsc krytycznych.

5.1 Konfiguracja środowiska programistycznego

System został zaimplementowany w oparciu o framework .NET 8.0 (Long Term Support), co zapewnia stabilność (trzyletnie wsparcie od producenta począwszy od 2023) oraz wysoką wydajność backendu [39]. Ze względu na wykorzystanie zewnętrznych bibliotek natywnych do przetwarzania danych przestrzennych (GDAL) oraz integrację z interpreterem języka Python, proces kompilacji aplikacji został sztywno zdefiniowany dla architektury procesora x64 [40].

W procesie implementacji wykorzystano następujące biblioteki zewnętrzne (pakiety NuGet):

- Oracle.ManagedDataAccess.Core (wersja 23.7.0). Oficjalny sterownik ADO.NET zapewniający wydajną komunikację z systemem Oracle Database. Biblioteka ta jest kluczowa dla obsługi zapytań do bazy danych oraz transkrypcji typów danych dostępnych w Oracle na te wspierane przez język C#.

- MaxRev.Gdal.Core (wersja 3.11.4). Wrapper dla biblioteki GDAL (Geospatial Data Abstraction Library). Odpowiada za niskopoziomowe operacje na danych przestrzennych, przede wszystkim surowych danych z plików rastrowych.

- pythonnet (wersja 3.0.5). Biblioteka zapewniająca interoperacyjność między środowiskiem .NET a interpreterem języka Python. Jest niezbędna do uruchamiania skryptów analitycznych, w tym implementacji algorytmu DBSCAN, bezpośrednio z poziomu kodu C#.

- ScottPlot (wersja 5.1.57). Biblioteka służąca do generowania wykresów. W systemie wykorzystana do renderowania map cieplnych (heatmap) reprezentujących wskaźnik NDVI na podstawie macierzy danych liczbowych.

- SixLabors.ImageSharp (wersja 3.1.11). Nowoczesna, w pełni zarządzana biblioteka graficzna do przetwarzania obrazów 2D. Wykorzystywana w warstwie serwisu do nanoszenia warstw wektorowych (np. granic pól w formacie GeoJSON) na mapy rastrowe.

- Microsoft.AspNetCore.Authentication.JwtBearer (wersja 8.0.3). Moduł oprogramowania pośredniego (Middleware) integrujący się z potokiem żądań ASP.NET Core, obsługujący uwierzytelnianie i autoryzację użytkowników przy pomocy tokenów JWT (JSON Web Token).

- Swashbuckle.AspNetCore (wersja 6.4.0). Zestaw narzędzi generujących interaktywną dokumentację API (zgodną ze specyfikacją OpenAPI/Swagger), co ułatwia testowanie punktów końcowych aplikacji w trakcie procesu deweloperskiego.

- Isopoh.Cryptography.Argon2 (wersja 2.0.0). Biblioteka implementująca algorytm Argon2 – zwycięzcę międzynarodowego konkursu Password Hashing Competition (PHC). W projekcie wykorzystywana jest do bezpiecznego, jednokierunkowego haszowania haseł użytkowników przed ich zapisem w bazie danych. Zapewnia wysoką odporność na ataki typu brute-force oraz ataki z wykorzystaniem dedykowanych układów obliczeniowych (GPU/ASIC), co stanowi kluczowy element w zakresie bezpieczeństwa systemu.

- System.IdentityModel.Tokens.Jwt (wersja 8.7.0). Biblioteka dostarczająca niskopoziomowe API do obsługi tokenów zgodnych z otwartym standardem RFC 7519 (JSON Web Token). W systemie odpowiada za fizyczne wygenerowanie obiektu tokena, zdefiniowanie jego zawartości (tzw. *claims*, np. ID użytkownika, rola) oraz jego cyfrowe podpisanie i serializację do formatu tekstowego w momencie pomyślnego logowania.

W toku prac projektowych część wykorzystanych bibliotek zewnętrznych otrzymała aktualizacje od dostawców. Mając jednak na uwadze stabilność środowiska produkcyjnego oraz ryzyko wystąpienia błędów regresji, podjęto decyzję o utrzymaniu wersji bibliotek zweryfikowanych na etapie implementacji. Takie podejście gwarantuje spójność działania systemu, natomiast migracja do najnowszych wydań pakietów została uwzględniona w planach dalszego rozwoju.

5.2 Inicjalizacja i konfiguracja aplikacji

Punktem wyjścia dla uruchomienia systemu jest konfiguracja parametrów środowiskowych oraz zdefiniowanie potoku przetwarzania żądań HTTP. W technologii .NET 8 zastosowano model instrukcji najwyższego poziomu (Top-level statements), który upraszcza strukturę pliku startowego, eliminując zbędny kod.

Wszelkie parametry zmienne, takie jak ciągi połączeniowe do bazy danych, czy ścieżki do zewnętrznych bibliotek, zostały oddzielone od kodu źródłowego i umieszczone w pliku appsettings.json. Również klucze szyfrujące na potrzeby prezentacji znalazły się w tym miejscu, jednakże dalszy rozwój projektu zakłada przeniesienie ich w miejsce niedostępne dla niepożądanych (Secrets.json, mechanizm User Secrets). Ułatwia to wdrażanie aplikacji na różnych środowiskach bez konieczności ponownej kompilacji.

Kolejnym krokiem jest konfiguracja kontenera wstrzykiwania zależności (Dependency Injection) oraz potoku przetwarzania żądań HTTP (Middleware Pipeline). W pliku Program.cs zarejestrowano wszystkie serwisy systemu Filskane, w tym warstwę dostępu do danych (DAL) oraz integracje zewnętrzne.


Ze względu na potrzebę wykorzystania zaawansowanych algorytmów analizy danych (biblioteka scikit-learn), system został zintegrowany z interpretatorem języka Python. Aby uniknąć opóźnień związanych z komunikacją sieciową (mikroserwisy), zastosowano bibliotekę Python.Runtime, która pozwala na uruchamianie kodu Python bezpośrednio w procesie pamięci aplikacji .NET.

5.3 Logowanie i rejestracja

Użytkownikowi udostępniana jest możliwość utworzenia prywatnego konta oraz każdorazowego logowania, aby uzyskać dostęp do danych. Jest to podstawowa funkcjonalność otrzymana w wyniku dążenia do chmurowego formatu aplikacji i przetwarzania informacji. Rolnik może zalogować się w każdym miejscu i na dowolnym urządzeniu, wystarczającym jest warunek dostępu do Internetu. Ponadto chroni to przed nieumyślną utratą danych – wszystkie rekordy są przechowywane na

zewnętrznej bazie danych, dobrze zoptymalizowanej pod kątem gromadzenia ogromnych ich zbiorów.

Poniższy rysunek przedstawia stronę logowania aplikacji, intuicyjnie zaprojektowaną, z możliwością wejścia w opcję rejestracji.



Rysunek 5.1 - Okno logowania (Zdjęcie w tle pochodzi z serwisu Pexels.com, autor: Jannis Knorr)

Idea jak i praca nad kodem powiązanym z funkcjonalnością nie wiązały się z problemami, ich istnienie zaś wynika z prostego połączenia tematu aplikacji webowe z potrzebą gromadzenia prywatnych danych i wykonywanych analiz, niedostępnych dla innych użytkowników.

5.4 Moduł GIS – Zarządzanie Gospodarstwem i Polami

Moduł mapowy w zakładce „Twoje gospodarstwo” umożliwia czytelne odwzorowanie gospodarstwa rolnego w aplikacji, co stanowi ważny cel w rolnictwie precyzyjnym. Został on zaimplementowany, wykorzystującą bibliotekę Leaflet do renderowania map, Turf.js do obliczeń przestrzennych po stronie klienta, wreszcie dane ewidencji działek pobrane z systemu Geoportal. Interfejs użytkownika realizuje trzy kluczowe scenariusze użycia: wskazanie lokalizacji gospodarstwa (obowiązkowo, jeśli jeszcze nie wykonał tej czynności), wyświetlenie konturów wszystkich pól użytkownika na mapie oraz możliwość dodawania nowych pól wykorzystaniem podkładu WMS (Ewidencja Gruntów i Budynków).



Rysunek 5.2 - Mapa gospodarstwa


Każdy obiekt na mapie, po naciśnięciu, generuje popup. Dla gospodarstwa istnieje funkcjonalność zmiany położenia oraz usunięcia. Każde pole daje możliwość podejrzenia informacji o nim (następuje przeniesienie do panelu pola) oraz usunięcia rekordu (wraz ze wszystkimi powiązаныmi skanami).

Dodawanie pola


Funkcjonalność dodawania pola jest podstawową i najważniejszą (poza samą prezentacją) operacją, jaką użytkownik może wykonać w tej sekcji. Kliknięcie w przycisk w prawym górnym rogu mapy powoduje otwarcie modalu z warstwą mapy OpenStreetMap oraz nałożoną na nią warstwą działek ewidencyjnych systemu Geoportal (istotne – warstwa działek generuje się po ustawieniu odpowiedniej skali, potocznie „zoom”). Klient może przenieść się do konkretnego miejsca na mapie (wybór miejscowości), a następnie, wybierając opcję po lewej stronie, zaznaczać kolejne wierzchołki wielokąta obrazującego pole, do momentu zamknięcia (dojścia do pierwszego wierzchołka). Warstwa frontendowa oblicza centroid pola oraz jego pole powierzchni w metrach kwadratowych. Pobrane dane są wysyłane do warstwy kontrolerów, a następnie serwisów, gdzie poprzez zapytanie HTTP pobierane są informacje o glebie dla punktu centralnego pola. Po tej operacji w warstwie dostępu do danych budowane jest zapytanie typu INSERT, tworzące w bazie nowe pole. W przypadku braku

błądów użytkownik widzi pozytywny komunikat, a wielokąt jest od razu rysowany na głównej mapie strony.


Diagram na rysunku 5.3 ilustruje proces dodawania pola po stronie programu:




Rysunek 5.3 - Diagram sekwencji dodawania pola



Rysunek 5.4 - Proces rysowania pola



Rysunek 5.5 - Nadawanie nazwy polu



Rysunek 5.6 - Pomyślne utworzenie pola

Opisana funkcjonalność jest kluczowa dla działania całej aplikacji. Możliwość analizy zdjęć wielospektralnych istnieje jedynie dla wcześniej zdefiniowanych pól. Co więcej, system wymaga, aby importowane skany satelitarne obejmowały cały obszar powiązanego z nimi wielokąta (weryfikacja następuje poprzez porównanie współrzędnych geograficznych).

W procesie implementacji systemu istotnym wyzwaniem był wybór sposobu przechowywania współrzędnych geograficznych (szerokość i długość geograficzna układu odniesienia WGS 84) w bazie danych. Użytkownik może zdefiniować nieograniczoną liczbę pól, a przewidywana liczba klientów w wersji produkcyjnej również jest znaczna. Jako standard

zapisu przyjęto format GeoJSON. Jest to specyficzny format obiektu JSON, dostosowany do reprezentacji danych przestrzennych. Charakteryzuje się on jednak strukturą tekstową, co przy skomplikowanych geometriach generuje dane o często znacznym rozmiarze. Wykorzystanie w tym przypadku standardowej kolumny typu VARCHAR2 w bazie Oracle było niemożliwe ze względu na sztywne limity długości ciągu znaków. W przypadku skomplikowanych granic pól, definicja GeoJSON może liczyć dziesiątki tysięcy znaków, co przy użyciu typu VARCHAR2 prowadziłoby do błędów przepełnienia bufora (standardowy limit to 4000 znaków) i uniemożliwiłoby zapis danych.


Początkowo rozważano użycie typu CLOB (Character Large Object), przystosowanego do przechowywania dużych ciągów znaków. Stanowił on rozwiązanie bezpieczniejsze niż VARCHAR2, pozwalając na zapis kompletnych struktur geometrycznych bez ryzyka utraty danych. Jednakże w nowszych wersjach systemu Oracle Database wprowadzono natywny typ danych JSON. Jest on dedykowany do przechowywania dokumentów w tym formacie i, w przeciwieństwie do tekstowego CLOB, wewnątrz bazy przechowuje dane w zoptymalizowanej formie binarnej (OSON). Rozwiązanie to, finalnie zaimplementowane w projekcie, zapewnia znacznie wyższą wydajność zapytań i obróbki danych po stronie serwera bazy.

Ostatecznie uzyskano skuteczną implementację fundamentu systemu rolnictwa precyzyjnego, jakim jest wierne odwzorowanie gospodarstwa w środowisku wirtualnym.

5.5 Procedura Importu Danych Satelitarnych

Wszystkie funkcjonalności dotyczące analizy pola są dostępne z poziomu określonego dla każdego z nich panelu zarządzania. Dostać się do niego można poprzez listę pól w zakładce Skanuj pole lub kliknięcie w wielokąt pola na mapie gospodarstwa.


Panel ten łączy wszystkie informacje o polu, prezentując dane zdefiniowane podczas tworzenia (nazwa, powierzchnia całkowita, klasa bonitacyjna gleby) oraz umożliwiając edycję parametrów dynamicznych, takich jak rodzaj uprawianej rośliny czy data ostatniego siewu.



Rysunek 5.7 - Panel zarządzania polem

Centralnym elementem interfejsu jest moduł przedstawiający ostatnie zdjęcie (według daty) pola w formacie RGB, na rysunku 5.7 jeszcze niewidoczne. System umożliwia import danych teledetekcyjnych oraz przeglądanie historii skanów wykonanych w przeszłości, a także analizę obrazów wielospektralnych pod kątem wskaźnika NDVI.

Diagram na rysunku 5.8 przedstawia tok importu zdjęcia satelitarnego do aplikacji:



Rysunek 5.8 - Diagram sekwencji importu skanu

Proces wgrywania zdjęcia do systemu rozpoczyna się od wywołania okna dialogowego wyboru plików. Ze względu na specyfikę danych wielospektralnych, system wymaga dostarczenia archiwum w formacie .zip, zawierającego cztery kluczowe kanały spektralne (pasma) zgodne ze standardem satelity:

- **B02** (Blue – pasmo niebieskie),
- **B03** (Green – pasmo zielone),
- **B04** (Red – pasmo czerwone),
- **B08** (NIR – bliska podczerwień).

System waliduje nazewnictwo plików zgodnie ze standardem Sentinel-2 wewnątrz archiwum (powyższe kody powinny być częścią nazwy plików), co jest niezbędne do poprawnego scalenia kanałów w procesie realizowanym przez bibliotekę GDAL. Użytkownik zobligowany jest również do podania daty wykonania skanu, co pozwala na zachowanie chronologii w module historii.

Walidacja Przestrzenna i Przetwarzanie

Istotnym etapem importu jest weryfikacja poprawności geograficznej dostarczonych danych. System odczytuje metadane przestrzenne z przesłanych plików GeoTIFF i wyznacza ich zakres graniczny (a więc pozycję skanu w przestrzeni). Następnie realizowany jest algorytm porównawczy, sprawdzający, czy geometria pola użytkownika (zdefiniowana jako wielokąt GeoJSON) zawiera się całkowicie w obszarze objętym przez zdjęcie satelitarne.

W przypadku negatywnej walidacji (gdy skan nie pokrywa obszaru pola), proces jest przerywany, a system zwraca wyjątek z odpowiednim komunikatem dla użytkownika.

Przechowywanie Rekordów i Wykorzystanie Oracle Spatial

Po pomyślnej walidacji przestrzennej i przetworzeniu pasm w jeden obraz w pamięci operacyjnej serwera, następuje proces trwałego zapisu. Ze względu na specyfikę danych rastrowych, system wykorzystuje silnik Oracle Database z rozszerzeniem Spatial and Graph. Pozwala to na składowanie obrazów nie jako zwykłych obiektów binarnych (BLOB), ale jako natywnych struktur MDSYS.SDO_GEORASTER. Powyższe rozwiązanie zapewnia

możliwość łatwego przechowywania danych rastrowych o dużej ilości pasm oraz łatwą ich izolację od innych.

Transmisja przetworzonego pliku GeoTIFF z warstwy DAL do bazy danych odbywa się w dwóch etapach:

1. Tablica bitowa zawierająca scalony obraz jest przesyłana jako parametr zapytania SQL.
2. Tworzona jest procedura składowa PL/SQL, gdzie następuje konwersja surowego obiektu BLOB na strukturę GeoRaster. Wykorzystywana jest do tego funkcja SDO_GEOR.importFrom, która automatycznie konfiguruje obiekt GeoRaster w tabeli docelowej.

Budowa procedury PL/SQL widnieje w kodzie 5.1.

```
DECLARE
    v_geor MDSYS.SDO_GEORASTER;
BEGIN
    SELECT RASTER INTO v_geor
    FROM SATELLITE_SCANS
    WHERE SCAN_ID = :id FOR UPDATE;

    SDO_GEOR.importFrom(v_geor, '', 'TIFF', :blob);

    UPDATE SATELLITE_SCANS
    SET RASTER = v_geor
    WHERE SCAN_ID = :id;
END;
```

Kod 5.1 - Zapis rastra w bazie danych

Wykorzystanie wbudowanej procedury SDO_GEOR.importFrom eliminuje konieczność instalacji zewnętrznych bibliotek (np. sterowników GDAL) w systemie Oracle. Dzięki temu logika składowania danych jest prosta, w pełni hermetyczna i niezależna od konfiguracji serwera bazy danych, co znacząco minimalizuje ryzyko wystąpienia błędów regresji przy aktualizacjach oprogramowania zewnętrznego.


Zastosowanie typu danych SDO_GEORASTER stanowi kolejny krok w optymalizacji dużych zbiorów danych przestrzennych. Projektowany system musi być przygotowany na składowanie znacznych ilości skanów.

Przykładowo, satelity Sentinel-2 w umiarkowanych szerokościach geograficznych (w tym nad Polską) mogą dostarczać zdjęcia tego samego obszaru nawet co 2–3 dni. Oznacza to, że jedno pole może generować rocznie ponad 100 rekordów, których czas archiwizacji sięga wielu lat.

Wykorzystanie SDO_GEOASTER znacząco podnosi efektywność przechowywania rastra oraz przyspiesza dostęp do danych binarnych. Mechanizm ten umożliwia bezpośredni import i eksport plików TIFF, bez potrzeby specjalnego parsowania na konkretny typ. Istotnym atutem są również szerokie możliwości przetwarzania zdjęć bezpośrednio na serwerze bazy danych. W przyszłości, przy rozbudowie systemu o analizę wielokanałową czy ekstrakcję złożonych cech, pozwoli to na odciążenie warstwy aplikacji i dalszą optymalizację wydajności.

5.6 Wizualizacja NDVI

Funkcjonalność wizualizacji wskaźnika NDVI dla zaimportowanego skanu stanowi kluczowy element systemu w kontekście rolnictwa precyzyjnego. Wykorzystując wzór 3.1, aplikacja oblicza wartość indeksu dla każdego piksela obrazu, prezentując wynik w postaci mapy barwnej (heatmapy) z wykorzystaniem gradientu odcieni zieleni. Proces ten inicjowany jest przez użytkownika poprzez wybór opcji „Analiza NDVI”.



Rysunek 5.9 - Wizualizacja NDVI

Po otrzymaniu żądania, aplikacja pobiera dane obrazu z bazy, które następnie w formie tablicy bajtów przekazywane są do warstwy logicznej. Tam, przy wykorzystaniu biblioteki GDAL, następuje odczyt wartości

kanałów pasma czerwonego oraz bliskiej podczerwieni dla każdego piksela i wyznaczenie indeksu. Wynikiem operacji jest macierz wartości zmiennoprzecinkowych podwójnej precyzji, o wymiarach odpowiadających analizowanemu zdjęciu. Obiekt ten stanowi podstawę do wygenerowania mapy rastrowej, zwracanej do warstwy prezentacji w formacie PNG.

Istotnym dodatkiem jest nałożenie na wynikowy obraz wektorowych granic pola, co znacząco ułatwia orientację przestrzenną i interpretację danych. Dodatkowo, interfejs wyposażono w legendę, która pozwala użytkownikowi na wstępną ocenę kondycji roślin jeszcze przed uruchomieniem zaawansowanych algorytmów analitycznych.

Istotną optymalizacją architektury jest rozdzielenie procesu pobierania danych numerycznych od ich wizualizacji na dwa niezależne endpointy. Pierwszy z nich przekazuje do warstwy frontendowej dwuwymiarową tablicę wartości (reprezentującą macierz NDVI, przechowywaną jako lista list), która jest następnie buforowana w pamięci przeglądarki. Tak zmagazynowane dane są przesyłane z powrotem do serwera w celu wygenerowania graficznej mapy ciepła. Mechanizm ten wprowadzono w celu redukcji obciążenia obliczeniowego – algorytm grupowania operuje na tym samym zbiorze danych, co wizualizacja. Dzięki takiemu podejściu eliminuje się konieczność wielokrotnego, kosztownego przetwarzania plików rastrowych. W przypadku braku danych w pamięci podręcznej klienta, system automatycznie inicjuje pełną ścieżkę pobrania i przeliczenia skanu z bazy danych.

Jak wspomniano w rozdziale 3.5, wskaźnik NDVI stanowi fundament analizy spektralnej upraw. Uzyskane wyniki są integralną częścią procesów decyzyjnych prowadzących do optymalizacji zasobów, a w połączeniu z technologią Internetu Rzeczy – umożliwiają automatyzację zabiegów agrotechnicznych. Dzięki precyzyjnym mapom wegetacji maszyny rolnicze mogą dynamicznie dostosowywać dawkowanie nawozów, tak aby każdy fragment pola otrzymał optymalną ilość substancji odżywczych.

Optymalizacja obliczeń jest niezwykle istotna. Pominięcie zapisu macierzy NDVI w buforze powodowałoby zwiększone obciążenie nie tylko samej aplikacji, ale również bazy danych, do których docierałoby dwa razy więcej zapytań, z których połowa zupełnie niepotrzebnie. Mnożąc to przez ilość potencjalnych użytkowników otrzymany zostałby system wysoce


nieefektywny, co przełożyłoby się przede wszystkim na złe odczucia związane z użytkowaniem aplikacji (powole procesy). Powyższe działania pozwalają uniknąć takich sytuacji, polepszając wrażenia rolnika z pracy z systemem jak również przyspieszając same procesy decyzyjne.

5.7 Moduł Analizy Zaawansowanej – Klastrowanie DBSCAN

W celu automatyzacji procesu wykrywania zagrożeń, system wyposażono w moduł uczenia maszynowego, realizujący zadanie segmentacji obrazu. System samodzielnie identyfikuje zwarte obszary (klastry) o niepokojąco niskim wskaźniku wegetacji, co rozwija i dopełnia subiektywną ocenę mapy przez użytkownika.

Wykorzystany algorytm DBSCAN w przeciwieństwie do popularnego k-Means nie wymaga wcześniejszego zdefiniowania liczby klastrów i doskonale radzi sobie z wykrywaniem obiektów o nieregularnych kształtach, typowych dla chorób roślin czy szkód powodowanych przez warunki atmosferyczne lub zwierzęta.

Funkcjonalność grupowania jest dostępna z poziomu okna wizualizacji NDVI. Naciśnięcie przycisku powoduje uruchomienie sekwencji, której diagram przedstawiony jest poniżej:



Rysunek 5.10 - Diagram sekwencji klastrowania DBSCAN

Warunkiem koniecznym do poprawnego działania algorytmu jest zdefiniowanie fazy rozwoju uprawy na danym polu. Wymaga to wprowadzenia przez użytkownika nazwy rośliny oraz daty siewu. Na podstawie tych danych wyznaczany jest parametr cyklu rozwojowego, niezbędny do dalszej klasyfikacji.

Sam proces analizy składa się z pięciu etapów:

1. Do warstwy biznesowej aplikacji przekazywana jest macierz NDVI (reprezentowana jako lista list) wraz z parametrami konfiguracyjnymi. Wykorzystano tu mechanizm optymalizacji opisany wcześniej – jeżeli macierz została już obliczona na potrzeby wizualizacji, aplikacja wykorzystuje te dane, nie wykonując ponownych przeliczeń rastra.
2. Z bazy danych pobierane są dwie wartości graniczne wskaźnika NDVI, właściwe dla aktualnego etapu wzrostu danej rośliny. Wartości poniżej progu dolnego oznaczają rośliny zagrożone, powyżej górnego – rośliny o prawidłowej kondycji.
3. Następuje filtracja przestrzenna punktów (pikseli). Sprawdzane jest, czy dany punkt zawiera się wewnątrz wielokąta definiującego granice pola. Punkty należące do geometrii pola zapisywane są w tymczasowej strukturze danych.
4. Funkcja pomocnicza dokonuje klasyfikacji przefiltrowanych punktów w oparciu o ich wartość NDVI, przypisując im jedną z trzech kategorii: stan zdrowy, zadowolający lub zagrożony (choroba).
5. Punkty zaklasyfikowane jako zagrożone (klasa 2) są wyodrębniane do osobnej tabeli w celu dalszej analizy.

Tak przygotowany zbiór punktów poddawany jest grupowaniu przy użyciu algorytmu DBSCAN. Parametr `eps` (gęstość klastra) jest konfigurowalny z poziomu aplikacji, natomiast parametr `min_samples` (promień sąsiedztwa) ustalono na stałą wartość 3.

Dla każdego wykrytego klastra obliczana jest średnia wartość NDVI, co pozwala na ocenę stopnia uszkodzenia roślin w danym skupisku. Zidentyfikowane obszary nanoszone są na mapę w postaci nowej warstwy graficznej. Użytkownik otrzymuje czytelną informację wizualną, gdzie pola o odcieniach czerwieni oznaczają zwarte obszary problematyczne,

a pojedyncze punkty nieformujące skupisk (szum) są pomijane dla zachowania czytelności.



Rysunek 5.11 - Grupowanie zagrożeń

Wykorzystanie algorytmu grupowania stanowi strategiczny element całego systemu, pozwalający na inteligentne zarządzanie strefami zagrożenia. Sama identyfikacja pikseli o niskim wskaźniku NDVI bywa niewystarczająca – mogą one stanowić jedynie szum informacyjny lub błąd pomiarowy. Dopiero zgrupowanie ich w zwarte klastry pozwala na odróżnienie losowych zakłóceń od realnych problemów agrotechnicznych. Dzięki temu użytkownik otrzymuje informację nie tylko o tym, gdzie występuje anomalia, ale także jaka jest jej skala i struktura. Jest to kluczowe dla doboru odpowiednich narzędzi – inne działania podejmuje się dla małych, punktowych ognisk choroby, a inne dla rozległych stref wymagających systemowego oprysku. W efekcie system nie tylko „pokazuje” problem, ale przygotowuje dane wejściowe dla maszyn rolniczych realizujących precyzyjne zabiegi.

Podczas prac nad systemem istotnym wyzwaniem inżynierskim była integracja logiki biznesowej (backendu .NET) z modułem analitycznym zaimplementowanym w języku Python. Po analizie dostępnych rozwiązań, zdecydowano się na wykorzystanie biblioteki **Python.NET**. Pozwala ona na uruchomienie środowiska Python bezpośrednio wewnątrz procesu maszyny wirtualnej .NET (CLR), co znacząco upraszcza architekturę i eliminuje narzut czasowy związany z przesyłem danych (brak konieczności

komunikacji sieciowej). Jest to rozwiązanie optymalne dla prezentacji założeń systemu w fazie prototypowej. Należy jednak zaznaczyć, że w przypadku potencjalnego wdrożenia komercyjnego, rekomendowanym kierunkiem rozwoju jest przejście na architekturę mikroserwisów. Wydzielenie modułu analitycznego do niezależnego serwisu pozwoli na lepszą skalowalność i obsługę dużej liczby równoległych sesji, nawet kosztem niewielkich opóźnień komunikacyjnych.

5.8 Dodatkowe funkcjonalności i personalizacja systemu

Uzupełnieniem kluczowych modułów analitycznych jest zestaw funkcjonalności wspierających codzienną obsługę systemu oraz zwiększających ergonomię pracy użytkownika. Aplikacja została zaprojektowana jako wszechstronna, dbając nie tylko o przetwarzanie obrazu, ale również o komfort interakcji i dostęp do danych pomocniczych.

Istotnym aspektem jest moduł pogodowy, zintegrowany z zewnętrznym interfejsem API serwisu OpenMeteo. Rolnictwo precyzyjne wymaga uwzględniania warunków atmosferycznych przy planowaniu zabiegów agrotechnicznych (np. unikanie oprysków przy silnym wietrze). System prezentuje w czasie rzeczywistym kluczowe parametry, takie jak temperatura, prędkość wiatru oraz pogodę, ubraną w przystępne ikony dla lokalizacji gospodarstwa. Dane te pobierane są asynchronicznie, co nie opóźnia ładowania głównego interfejsu.



Rysunek 5.12 - Interfejs pogodowy

W warstwie prezentacji duży nacisk położono na możliwości personalizacji. Zaimplementowano obsługę motywów graficznych (tryb jasny i ciemny), co ma istotne znaczenie dla czytelności danych w różnych warunkach oświetleniowych – np. podczas pracy w terenie na tablecie w pełnym słońcu lub wieczorem przy komputerze, jak również komfortu użytkownika. Dodatkowo, system umożliwia dynamiczną zmianę jednostek powierzchni. Użytkownik może przełączać się między hektarami, arami a akrami, co pozwala na dostosowanie aplikacji zarówno do specyfiki małych gospodarstw, jak i standardów międzynarodowych.

Aplikacja zapewnia również pełną kontrolę nad danymi konta. Użytkownik posiada możliwość edycji swoich danych osobowych oraz bezpiecznej zmiany hasła. Zgodnie z dobrymi praktykami ochrony danych oraz wymogami prywatności, zaimplementowano również funkcję trwałego usunięcia konta. Operacja ta jest nieodwracalna i skutkuje kaskadowym usunięciem wszystkich powiązanych rekordów z bazy danych Oracle (w tym zdefiniowanych pól, historii skanów oraz analiz), realizując tym samym prawo użytkownika do bycia zapomnianym.

6 Wnioski i kierunki dalszego rozwoju

Zrealizowany system stanowi stabilną i funkcjonalną aplikację, realizującą wszystkie założenia sformułowane w temacie pracy. Zaimplementowana funkcjonalność detekcji oraz klasteryzacji zagrożonych fragmentów upraw wspomaga proces zarządzania gospodarstwem, umożliwiając automatyzację kluczowych decyzji i optymalizację kosztów agrotechnicznych. Wykorzystanie relacyjnej bazy danych Oracle pozwoliło na efektywne składowanie i przetwarzanie dużych zbiorów danych, w szczególności danych przestrzennych (rastrów i wektorów). Zastosowanie algorytmów grupowania (z dziedziny sztucznej inteligencji) pozwala na segmentację stref zagrożeń na klastry o określonych parametrach, co w praktyce przekłada się na precyzyjną ocenę kondycji roślin i możliwość celowanych działań naprawczych.

Interfejs aplikacji webowej charakteryzuje się wysoką elastycznością i intuicyjną nawigacją, co jest kluczowe dla użytkownika końcowego oczekującego narzędzia czytelnego i ergonomicznego. Decyzja o oparciu

warstwy prezentacji na natywnych technologiach HTML5 i CSS3 zapewniła pełną separację frontendu od logiki biznesowej (backendu). Zastosowanie czystego JavaScriptu jako łącznika stanowi alternatywę dla rozwiązań silnie wiążących warstwę wizualną z serwerową (jak Razor czy Flask). Takie podejście, mimo wyższego progu wejścia, gwarantuje modularność systemu i ułatwia potencjalną migrację technologiczną w przyszłości. Dodatkowym atutem jest czytelność kodu i możliwość niezależnego rozwoju obu warstw przez zespoły o różnych kompetencjach (rozdzielenie roli Frontend i Backend Developera).

W fazie projektowej przeanalizowano zasadność wykorzystania metod głębokiego uczenia, w tym konwolucyjnych sieci neuronowych (CNN). Choć są one wysoce skuteczne w rozpoznawaniu obrazów, w specyficznym przypadku analizy wskaźnika NDVI – który sprowadza się do operacji na macierzy wartości liczbowych – okazały się rozwiązaniem nadmiarowym. Wyższą efektywność osiągnięto, stosując algorytmy uczenia nienadzorowanego (DBSCAN) poprzedzone filtracją progową. Pozwoliło to na precyzyjne wyodrębnienie istotnych anomalii bez konieczności tworzenia rozbudowanych zbiorów treningowych.

Integracja systemu z OpenStreetMap oraz biblioteką Leaflet zapewniła wysoki komfort użytkowania. Wizualizacja granic gospodarstwa na interaktywnej mapie centralizuje proces zarządzania arealem. Rozwiązanie to stanowi solidny fundament pod przyszłą implementację Internetu Rzeczy, w tym śledzenie maszyn rolniczych w czasie rzeczywistym. Architektura systemu umożliwia w przyszłości agregację danych z czujników pojazdów, ich analizę oraz zwrotne przesyłanie informacji decyzyjnych do operatora.

Wraz z rozwojem aplikacji kluczowym kierunkiem będzie implementacja zaawansowanych metod analizy spektralnej. Rozszerzenie systemu o obsługę naziemnych czujników (np. wilgotności gleby) oraz połączenie tych danych z różnymi kanałami spektralnymi satelitów pozwoli na jeszcze dokładniejszą ocenę warunków wegetacji. Istotnym elementem rozwoju będzie również moduł predykcyjny, wykorzystujący szeregi czasowe, przeszłe rekordy pól oraz historyczne dane pogodowe do prognozowania plonów i ostrzegania przed zagrożeniami z odpowiednim wyprzedzeniem.

Duży potencjał rozwoju posiada moduł informacyjnopogodowy. Integracja z precyzyjnymi mapami pogodowymi oraz cyfrowym kalendarzem zabiegów agrotechnicznych stanowić będzie kompletne wsparcie w planowaniu prac polowych. Wartościowym dodatkiem byłoby również wprowadzenie do aplikacji branżowej bazy wiedzy, zawierającej aktualności rynkowe, porady agrotechniczne oraz informacje o ubezpieczeniach.

W kontekście ekspansji rynkowej niezbędne jest wdrożenie mechanizmu łatwej zmiany wersji językowej. Równie istotne jest opracowanie kompleksowego systemu pomocy (samouczka), który obniży próg wejścia dla użytkowników mniej biegłych cyfrowo. Planowany jest także rozwój systemu powiadomień wielokanałowych (SMS, E-mail), umożliwiających natychmiastową reakcję na krytyczne zmiany parametrów upraw.

Od strony inżynierii oprogramowania naturalnym krokiem jest wdrożenie pełnego zestawu testów automatycznych (jednostkowych i integracyjnych), co zapewni stabilność systemu przy wprowadzaniu zmian. Docelowa architektura produkcyjna powinna opierać się na wzorcu mikroserwisów, trwale separując warstwę biznesową od analitycznej. Planowana jest również głębsza optymalizacja warstwy danych poprzez pełne wykorzystanie możliwości przetwarzania wewnątrz bazy danych oferowanego przez typ SDO_GEORASTER w Oracle.

Zaprojektowana aplikacja to projekt o solidnych podstawach i dużym potencjale rozwojowym. Jego obecna architektura jest stabilna, a jednocześnie otwarta na rozbudowę. Kod źródłowy zachowuje czytelność i standardy inżynierskie, a interfejs użytkownika pozostaje przystępny, co czyni aplikację gotową na dalsze etapy cyklu życia oprogramowania. Spełnia ona wszystkie założenia tematu, będąc skuteczną pomocą dla rolnika z ramienia rolnictwa precyzyjnego.

7 Bibliografia:

- [1] Kose U. i inni, Artificial Intelligence and Smart Agriculture Technology, CRC Press; Taylor & Francis Group, 2022.
- [2] Lieberman B., Gordon E., Climate Change in Human History: Prehistory to the Present, Bloomsbury Academic, 2018.
- [3] Goedde L. i inni, Agriculture's connected future: How technology can yield new growth, <https://www.mckinsey.com/industries/agriculture/our-insights/agricultures-connected-future-how-technology-can-yield-new-growth>, McKinsey & Company, 2020.
- [4] Bhatnagar R. i inni, The Digital Agricultural Revolution: Innovations and Challenges in Agriculture through Technology Disruptions, Scrivener Publishing; Wiley, 2022.
- [5] Russell S.J., Norvig P., Artificial Intelligence: A Modern Approach (4th Edition), Pearson, 2022.
- [6] Biuro Analiz Parlamentu Europejskiego (EPRS), Rolnictwo precyzyjne a przyszłość rolnictwa w Europie: Prognoza naukowa, Jednostka ds. Oceny Rozwiązań Naukowych i Technicznych (STOA), 2016.
- [7] Ekielski A. i inni, Precyzyjne i inteligentne rolnictwo – stan i perspektywy wdrażania, Fundacja na rzecz Rozwoju Polskiego Rolnictwa (FDPA), 2023.
- [8] Fundacja na rzecz Rozwoju Polskiego Rolnictwa (FDPA), Webinar "Innowacje na polu. Praktyczne zastosowanie rozwiązań cyfrowych w rolnictwie precyzyjnym", <https://www.fdpa.org.pl/webinar-innowacje>, stan na dzień: 08.01.2026
- [9] Ahmad L., Nabi F., Agriculture 5.0: Artificial Intelligence, IoT and Machine Learning, CRC Press; Taylor & Francis Group, 2021.
- [10] Tomar P., Kaur G., Artificial Intelligence and IoT-Based Technologies for Sustainable Farming and Smart Agriculture, IGI Global, 2021.
- [11] Sabry F., Agricultural Robotics: How Are Robots Coming to the Rescue of Our Food, One Billion Knowledgeable, 2021.
- [12] Lipper L. i inni, Climate Smart Agriculture: Building Resilience to Climate Change, Springer, 2018.

- [13] Darji P. i inni, A Review: Applications of Remote Sensing in Agriculture, International Association of Biologicals and Computational Digest, Tom 2, 2023, s. 108–117.
- [14] Singh R. i inni, Artificial Intelligence in Agriculture, CRC Press, 2021.
- [15] Ester M. i inni, A density-based algorithm for discovering clusters in large spatial databases with noise, AAAI Press, 1996.
- [16] Patel G.S. i inni, Smart Agriculture: Emerging Pedagogies of Deep Learning, Machine Learning and Internet of Things, CRC Press, 2021.
- [17] Silberschatz A., Korth H.F., Sudarshan S., Database System Concepts, McGraw-Hill Education, 2020.
- [18] Oracle Corporation, Oracle Spatial and Graph Developer's Guide, <https://docs.oracle.com/en/database/oracle/oracle-database/18/spatl/index.html>, Oracle Corporation, stan na dzień: 08.01.2026
- [19] Kyte T., Kuhn D., Expert Oracle Database Architecture (3rd Edition), Apress, 2014.
- [20] Oracle Corporation, Oracle Database VLDB and Partitioning Guide, <https://docs.oracle.com/en/database/oracle/oracle-database/19/vldbg/>, Oracle Corporation, stan na dzień: 08.01.2026
- [21] Sommerville I., Software Engineering (10th Edition), Pearson, 2016.
- [22] Flanagan D., JavaScript: The Definitive Guide, O'Reilly Media, 2020.
- [23] Microsoft, Architecting Modern Web Applications with ASP.NET Core and Microsoft Azure, Microsoft Developer Division, 2023.
- [24] Oracle Corporation, Oracle Data Provider for .NET Developer's Guide, <https://docs.oracle.com/en/database/oracle/oracle-database/26/odpnt/index.html>, Oracle Corporation, stan na dzień: 08.01.2026
- [25] Fouda H.S., Information Technology in Agriculture, Delve Publishing, 2020.
- [26] Oracle Corporation, Oracle SQL Developer User's Guide, https://docs.oracle.com/cd/E39885_01/appdev.40/e38414/toc.htm, Oracle Corporation, stan na dzień: 08.01.2026
- [27] Oracle Corporation, Oracle Spatial and Graph Developer's Guide, <https://docs.oracle.com/en/database/oracle/oracle-database/>

[database/18/spatl/index.html](https://docs.oracle.com/en/database/oracle/oracle-database/21/adjsn/), Oracle Corporation, stan na dzień: 08.01.2026

[28] Oracle Corporation, Oracle Database JSON Developer's Guide, <https://docs.oracle.com/en/database/oracle/oracle-database/21/adjsn/>,

Oracle Corporation, stan na dzień: 08.01.2026

[29] Troelsen A., Japikse P., Pro C# 10: With .NET 6; Foundational Principles and Practices in Programming, Apress, 2022.

[30] Raschka S., Liu Y., Mirjalili V., Machine Learning with PyTorch and Scikit-Learn, Packt Publishing, 2022.

[31] Newman S., Building Microservices: Designing Fine-Grained Systems (2nd Edition), O'Reilly Media, 2021.

[32] Open Data Commons, Open Data Commons Open Database License (ODbL) v1.0, opendatacommons.org, stan na dzień: 08.01.2026

[33] Leaflet Contributors, Leaflet: an open-source JavaScript library for mobile-friendly interactive maps, leafletjs.com, stan na dzień: 08.01.2026

[34] Ustawa z dnia 17 maja 1989 r. Prawo geodezyjne i kartograficzne, Dz.U. 2024 poz. 1151.

[35] Ustawa z dnia 11 sierpnia 2021 r. o otwartych danych i ponownym wykorzystywaniu informacji sektora publicznego, Dz.U. 2021 poz. 1641.

[36] Zippenfenig P., Open-Meteo: Free Weather API [Computer software], <https://open-meteo.com/>, Zenodo, stan na dzień: 08.01.2026.

[37] GDAL/OGR contributors, GDAL/OGR Geospatial Data Abstraction Library, <https://gdal.org/en/stable/>, Open Source Geospatial Foundation, stan na dzień: 08.01.2026

[38] Ozguven M. M., The Digital Age in Agriculture, Taylor & Francis Group, 2023.

[39] Microsoft, Announcing .NET 8. .NET Blog, <https://devblogs.microsoft.com/dotnet/announcing-dotnet-8/>, stan na dzień: 08.01.2026

[40] MaxRev, MaxRev.Gdal.Core (wersja 3.12.0), <https://www.nuget.org/packages/MaxRev.Gdal.Core>, NuGet Gallery, stan na dzień 08.01.2026

[41] Gates, D. M. i inni, Spectral properties of plants, Applied Optics, 1965.

8 Spis rysunków:

Rysunek 4.1 - Diagram przypadków użycia	24
Rysunek 4.2 - Diagram logiki aplikacji.....	27
Rysunek 4.3 - Diagram związków encji.....	32
Rysunek 5.1 - Okno logowania	43
Rysunek 5.2 - Mapa gospodarstwa.....	44
Rysunek 5.3 - Diagram sekwencji dodawania pola	45
Rysunek 5.4 - Proces rysowania pola	45
Rysunek 5.5 - Nadawanie nazwy polu	46
Rysunek 5.6 - Pomyślne utworzenie pola	46
Rysunek 5.7 - Panel zarządzania polem.....	48
Rysunek 5.8 - Diagram sekwencji importu skanu.....	48
Rysunek 5.9 - Wizualizacja NDVI.....	51
Rysunek 5.10 - Diagram sekwencji klastrowania DBSCAN	53
Rysunek 5.11 - Grupowanie zagrożeń	55
Rysunek 5.12 - Interfejs pogodowy	56

9 Streszczenie

Współczesne rolnictwo przechodzi fundamentalną transformację w kierunku modelu rolnictwa precyzyjnego, w którym kluczową rolę odgrywają cyfryzacja, automatyzacja procesów oraz zaawansowana analiza danych. Celem niniejszej pracy dyplomowej było zaprojektowanie i zaimplementowanie kompleksowego systemu informatycznego, wspomagającego rolnika w optymalizacji produkcji roślinnej poprzez wykorzystanie metod sztucznej inteligencji oraz relacyjnych baz danych.

Opracowane rozwiązanie to aplikacja webowa, działająca w architekturze wielowarstwowej, która integruje funkcjonalności Systemów Informacji Geograficznej z teledetekcją satelitarną. Warstwa prezentacji została zrealizowana przy użyciu technologii HTML5, CSS3 oraz JavaScript, co zapewniło wysoką wydajność oraz niezależność od zewnętrznych frameworków wizualnych. Do wizualizacji danych przestrzennych wykorzystano bibliotekę Leaflet, zintegrowaną z usługami mapowymi OpenStreetMap oraz krajowym systemem Geoportal, co umożliwia precyzyjne odwzorowanie granic pól oraz pobieranie danych o klasach bonitacyjnych gleby w czasie rzeczywistym.

Warstwa logiki biznesowej została zaimplementowana w technologii ASP.NET Core (.NET 8), pełniąc rolę centralnego węzła zarządzającego przepływem danych i autoryzacją. Ważnym aspektem inżynierskim projektu jest zaawansowane wykorzystanie systemu zarządzania bazą danych Oracle Database. Zaprojektowany schemat bazy efektywnie łączy dane ustrukturyzowane z danymi przestrzennymi. Do przechowywania wektorowych granic pól wykorzystano natywny format JSON, natomiast do składowania wielospektralnych obrazów satelitarnych zastosowano specjalistyczny typ obiektowy MDSYS.SDO_GEORASTER. Rozwiązanie to, wsparte procedurami składowanymi PL/SQL, umożliwia wydajne przetwarzanie i archiwizację dużych wolumenów danych rastrowych bezpośrednio po stronie serwera bazy danych.

Istotnym elementem systemu jest moduł analityczny, zrealizowany w modelu hybrydowym łączącym wydajność języka C# z potencjałem analitycznym języka Python. Integracja obu środowisk odbywa się poprzez bibliotekę Python.NET, co pozwala na uruchamianie skryptów .py wewnątrz

procesu maszyny wirtualnej platformy .NET. Aplikacja przetwarza surowe dane satelitarne, obliczając znormalizowany różnicowy wskaźnik wegetacji NDVI. Uzyskane macierze danych poddawane są następnie analizie z wykorzystaniem algorytmu uczenia maszynowego DBSCAN (Density-Based Spatial Clustering of Applications with Noise). Algorytm ten autonomicznie identyfikuje i grupuje piksele o anomalnych wartościach wskaźnika, tworząc mapy stref zagrożenia. Pozwala to na wykrywanie ognisk chorobowych lub stresu wodnego bez konieczności manualnej analizy całego obszaru pola.

System został uzupełniony o moduł pogodowy wykorzystujący API Open-Meteo oraz funkcjonalności personalizacji interfejsu. Całość rozwiązania charakteryzuje się skalowalnością i modułową budową, co umożliwia w przyszłości migrację do architektury mikroserwisów oraz rozbudowę o obsługę urządzeń IoT.

10 Abstract

Modern agriculture is being transformed and undergoing through change towards precision agriculture, where digitalization, process automation and advance data analysis play key role. The objective of this paper is to design and implement comprehensive IT system, providing support to a farmer in plant production optimization by means of AI solutions and post-relational data bases.

The developed solution is a web application, running in the multilayered architecture which merged geographical information system with spectral analysis. The presentation layer (frontend) has been developed by using HTML5, CSS3 and JavaScript technologies, that ensured high performance, independence from external visual frameworks. The Leaflet library was used to visualize special data combined with OpenStreetMap services and National Geoportal, which allows for the precise depiction of fields and downloading data on land quality classification in real time.

The business logic layer was implemented using ASP.NET Core (.NET 8) technology, serving as the central node for managing data flow and authorization. A key engineering aspect of the project is the advanced utilization of the Oracle Database management system. The designed database schema effectively integrates structured data with spatial data. The native JSON format was used to store vector field boundaries, while the specialized object type MDSYS.SDO_GEORASTER was employed for archiving multispectral satellite imagery. This solution, supported by PL/SQL stored procedures, enables efficient processing and archiving of large volumes of raster data directly on the database server side.

A significant component of the system is the analytical module, implemented in a hybrid model that combines the performance of C# with the analytical capabilities of Python. The integration of both environments is achieved through the Python.NET library, allowing for the execution of .py scripts within the virtual machine process of the .NET platform. The application processes raw satellite data, calculating the Normalized Difference Vegetation Index (NDVI). The resulting data matrices are then subjected to analysis using the DBSCAN (Density-Based Spatial Clustering

of Applications with Noise) machine learning algorithm. This algorithm autonomously identifies and clusters pixels with anomalous index values, generating maps of risk zones. This enables the detection of disease outbreaks or water stress without the need for manual analysis of the entire field area.

The system has been complemented by a weather module utilizing the Open-Meteo API, as well as interface personalization functionalities. The entire solution is characterized by scalability and a modular design, which facilitates future migration to a microservices architecture and expansion to support IoT devices.